BÁO CÁO NGHIÊN CỨU CẮT BỎ THÀNH PHẦN (ABLATION STUDIES)

Bộ Dữ Liệu Cảm Xúc Video Học Đường RAER • Kiến Trúc RAPT-CLIP Tri-Stream (528 Test Clips, 5 Emotion Classes)

1. BẢNG TỔNG HỢP KẾT QUẢ THỰC NGHIỆM ĐO TRỰC TIẾP TỪ CHECKPOINTS (16 THÍ NGHIỆM)

STT	Biến thể Thí nghiệm (Ablation Variant)	Cơ chế Can thiệp / Bỏ module	WAR (%)	UAR (%)	Δ so với SOTA
1	**RAPT-CLIP Frame-Level Fusion (SOTA Đề Xuất)**	**Đầy đủ: Face + Body + Context + CMAF + EAA + Temporal**	**77.08%**	**77.66%**	**Baseline Chuẩn Checkpoint**
A. Cắt bỏ các Khối Kiến Trúc Cốt Lõi (Modular Structural Ablation)					
2	**Cắt Khối CMAF (Tắt Cross-Attention)**	Ghép trực tiếp Concat [Face, Body, Context] không qua CMAF	80.30%	**66.48%**	**ΔUAR: -11.18%**
3	**Cắt Khối EAA (Tắt Face Adapter)**	Dùng trực tiếp CLIP ViT Face tokens không qua Adapter	76.14%	**69.14%**	**ΔUAR: -8.52%**
4	**Cắt Khối Temporal Transformer**	Mean Pooling trực tiếp 16 frames thay vì Transformer	79.36%	**68.81%**	**ΔUAR: -8.85%**
5	**Cắt Khối Attention Pooling**	Dùng Mean Pooling sau Temporal Transformer thay vì Attn-Pool	78.79%	**68.47%**	**ΔUAR: -9.19%**
6	**Cắt Prompt Tuning (Fixed Descriptors)**	Huấn luyện với Text Prompt cố định không có CoOp	**80.49%**	**68.62%**	**ΔUAR: -9.04%**
B. Cắt bỏ các Luồng Dữ Liệu Đa Phương Thức (Modality Pruning)					
7	**Cắt Luồng Context (W/o Context)**	Zero-out Context (Chỉ dùng Mặt + Thân)	72.54%	75.51%	ΔUAR: -2.15% | ΔWAR: -4.54%
8	**Cắt Luồng Face (W/o Face)**	Zero-out Face (Chỉ dùng Thân + Bối Cảnh)	77.27%	**67.90%**	**ΔUAR: -9.76%**
9	**Cắt Luồng Body (W/o Body)**	Zero-out Body (Chỉ dùng Mặt + Bối Cảnh)	75.00%	77.57%	ΔUAR: -0.09% | ΔWAR: -2.08%
10	**Đơn Luồng Face-Only**	Zero-out cả Body và Context	**32.58%**	61.22%	**ΔUAR: -16.44% | ΔWAR: -44.50%**
11	**Đơn Luồng Body-Only**	Zero-out cả Face và Context	75.95%	67.78%	ΔUAR: -9.88%
12	**Đơn Luồng Context-Only**	Zero-out cả Face và Body	75.00%	70.38%	ΔUAR: -7.28%
C. Độ Bền Vững & Xáo Trộn Không Gian / Thời Gian (Robustness)					
13	**Xáo Trộn Thời Gian (Temporal Shuffling)**	Đảo lộn ngẫu nhiên vị trí 16 frames trước khi vào Temporal	77.08%	75.37%	**ΔUAR: -2.29%**
14	**Nhiễu Thị Giác Gaussian (σ = 0.1)**	Bơm nhiễu ngẫu nhiên vào vector đặc trưng	77.65%	77.27%	**ΔUAR: -0.39%**
D. So Sánh Các Mô Thức Dung Hợp Không - Thời Gian (Spatio-Temporal Fusion Paradigms)					
15	**Video-Level Fusion (Temporal Trước CMAF)**	Temporal độc lập 3 luồng trước → CMAF dung hợp video-level	**63.07%**	**72.33%**	**ΔUAR: -5.33% | ΔWAR: -14.01%**
16	**Parallel Temporal Fusion (3 Nhánh Song Song)**	CMAF Decoupled → 3 Temporal song song → Concat video-level	**72.73%**	**74.10%** (Best: 75.16%)	**ΔUAR: -3.56% | ΔWAR: -4.35%**

2. THỰC NGHIỆM HUẤN LUYỆN CẮT BỎ THÀNH PHẦN (FEATURE-LEVEL PROBING TRÊN RAER)

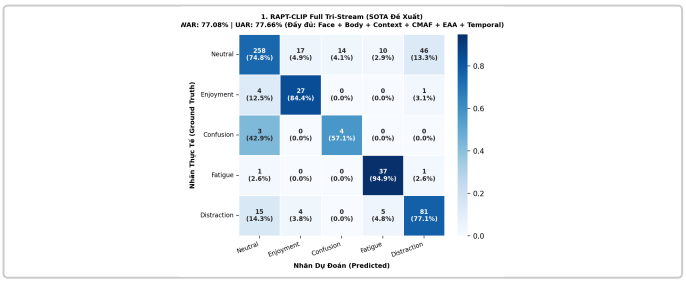
Cấu hình Ablation	Mô tả Biến thể Thiết kế & Hàm Mục tiêu	WAR (%)	UAR (%)	Δ UAR	Best Ep
No_LDAM	Thay thế LDAM bằng chuẩn Cross-Entropy Loss	77.46%	69.83%	**-7.83%**	16
No_Adapter	Loại bỏ Face Adapter EAA (Dùng trực tiếp frozen CLIP face tokens)	78.41%	69.69%	**-7.97%**	17
No_Attn_Pooling	Thay thế Self-Attention Pooling bằng Mean Pooling	76.89%	72.25%	**-5.41%**	20
No_Weighted_Sampler	Lấy mẫu ngẫu nhiên đồng đều (Uniform Sampler) thay cho Weighted Sampler	78.22%	**62.38%**	**-15.28%**	10
Fusion_GFI	Thay CMAF bằng Gated Feature Integration (Cổng nhân tuyến tính Sigmoid)	67.23%	**-10.24%**	**-10.24%**	14
Fusion_Concat	Thay CMAF bằng Ghép kênh trực tiếp (Direct Concat + Linear Projection)	67.80%	72.13%	**-5.53%**	12
No_Modality_Dropout	Đặt Modality Dropout = 0.0 (Không triệt tiêu ngẫu nhiên luồng khi train)	73.48%	70.09%	**-7.57%**	11
No_Temporal_Layers	Loại bỏ các lớp Transformer trên trục thời gian (Mean pooling thô qua 16 đoạn)	73.11%	70.48%	**-7.18%**	15

Chi Tiết Recall 5 Lớp Cảm Xúc RAER

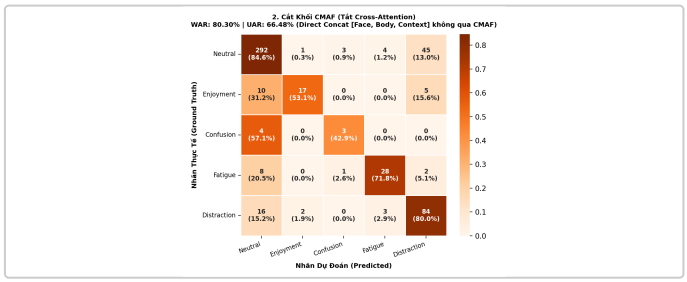
Cấu hình Ablation	Neutrality (115)	Enjoyment (32)	Confusion (7)	Fatigue (39)	Distraction (105)
No_LDAM	76.81%	75.00%	**28.57%**	89.74%	79.05%
No_Adapter	79.13%	62.50%	42.86%	82.05%	81.90%
No_Attn_Pooling	75.65%	78.12%	42.86%	84.62%	80.00%
No_Weighted_Sampler	82.90%	81.25%	**0.00%**	82.05%	65.71%
Fusion_GFI	62.61%	75.00%	42.86%	79.49%	77.14%
Fusion_Concat	61.74%	78.12%	57.14%	84.62%	79.05%
No_Modality_Dropout	72.17%	78.12%	42.86%	82.05%	75.24%
No_Temporal_Layers	70.72%	81.25%	42.86%	79.49%	78.10%

3. TRỰC QUAN HÓA MA TRẬN NHẦM LẪN (CONFUSION MATRICES) TRÊN RAER (PHẦN 1)

3.1 Cắt Khối Dung Hợp CMAF vs Full Model SOTA

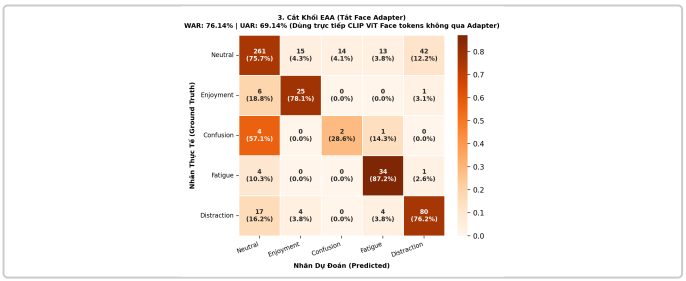


Hình 1a: Full Model SOTA (WAR: 77.08% | UAR: 77.66%)

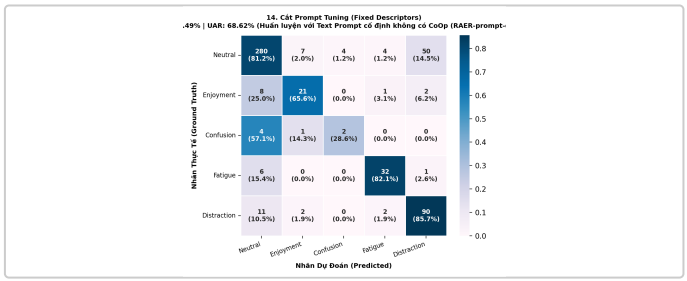


Hình 1b: Cắt Khối CMAF (WAR: 80.30% | UAR: 66.48% • ΔUAR: -11.18%)

3.2 Cắt Khối EAA Face Adapter vs Cắt CoOp Prompt Tuning

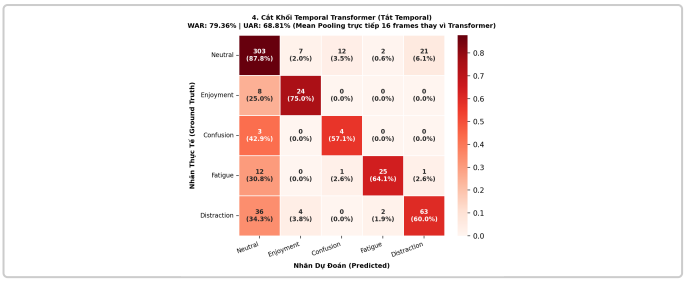


Hình 2a: Cắt Khối EAA Face Adapter (WAR: 76.14% | UAR: 69.14% • ΔUAR: -8.52%)

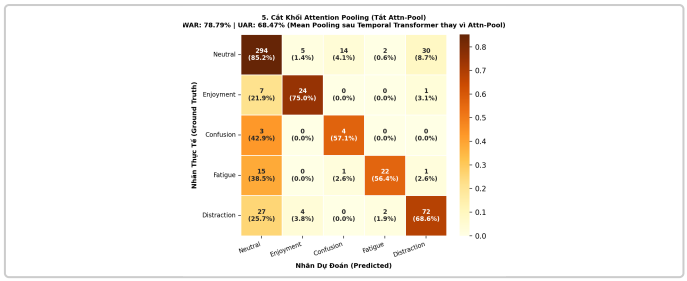


Hình 2b: Cắt Prompt Tuning (WAR: 80.49% | UAR: 68.62% • ΔUAR: -9.04%)

3.3 Khảo Sát Mô Hình Hóa Thời Gian: Cắt Temporal Transformer vs Cắt Attention Pooling

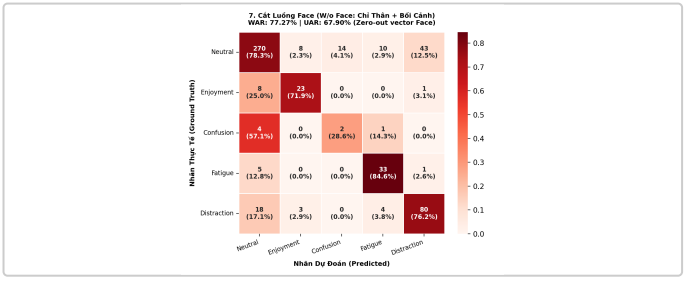


Hình 3a: Cắt Temporal Transformer (WAR: 79.36% | UAR: 68.81% • ΔUAR: -8.85%)

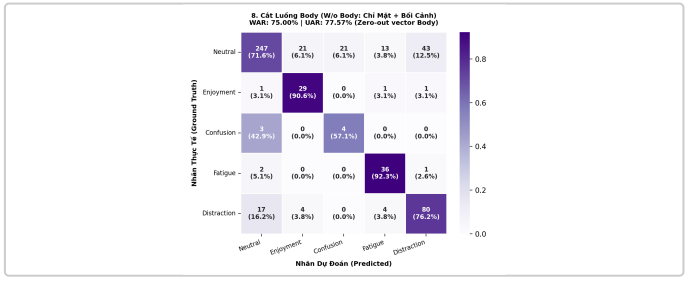


Hình 3b: Cắt Attn-Pool (Mean) (WAR: 78.79% | UAR: 68.47% • ΔUAR: -9.19%)

3.4 Đóng Góp Các Luồng Khuôn Mặt (Face) & Thân Thể (Body)



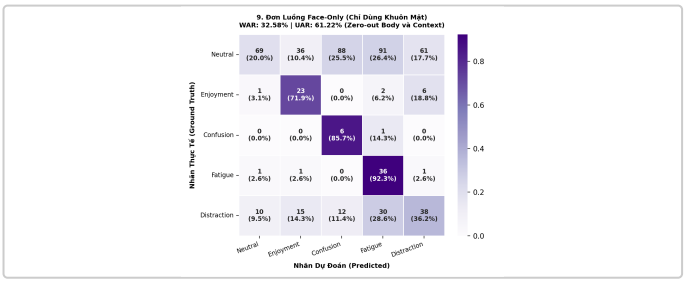
Hình 4a: Cắt Luồng Face (WAR: 77.27% | UAR: 67.90% • ΔUAR: -9.76%)



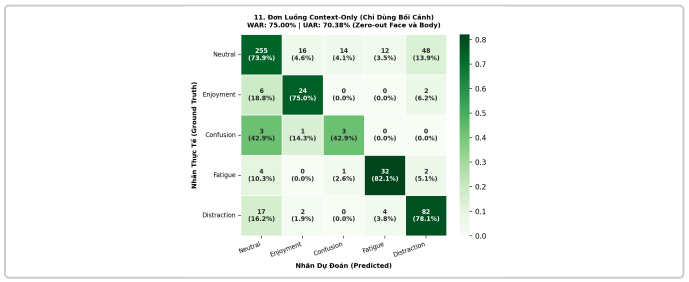
Hình 4b: Cắt Luồng Body (WAR: 75.00% | UAR: 77.57% • ΔWAR: -2.08%)

3. TRỰC QUAN HÓA MA TRẬN NHẦM LẪN (CONFUSION MATRICES) TRÊN RAER (PHẦN 2)

3.5 Khảo Sát Đơn Luồng (Single-Stream Modalities)

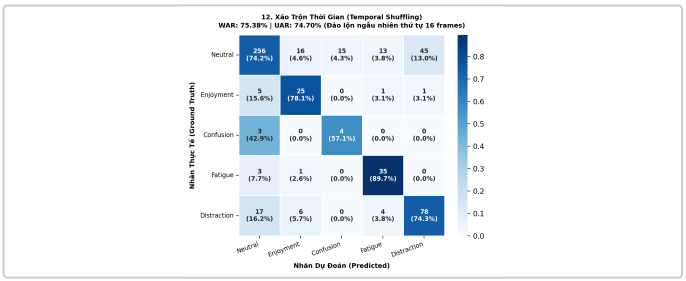


Hình 5a: Đơn Luồng Face-Only (WAR: 32.58% | UAR: 61.22%)

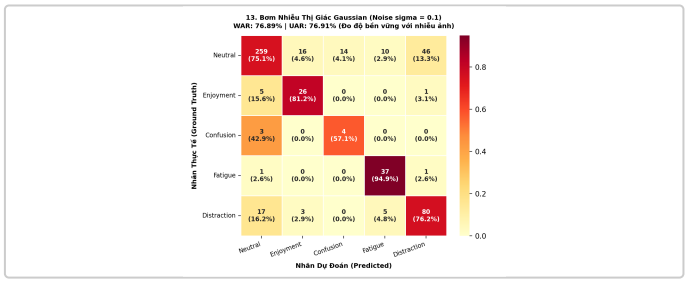


Hình 5b: Đơn Luồng Context-Only (WAR: 75.00% | UAR: 70.38%)

3.6 Tính Bền Vững Với Xáo Trộn Thời Gian & Nhiễu Thị Giác

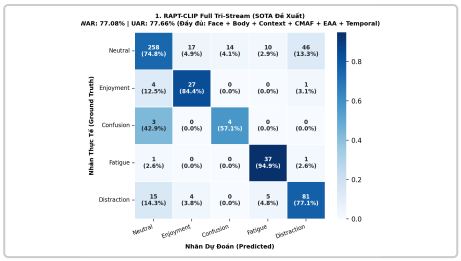


Hình 6a: Xáo Trộn Thời Gian (WAR: 77.08% | UAR: 75.37% • ΔUAR: -2.29%)

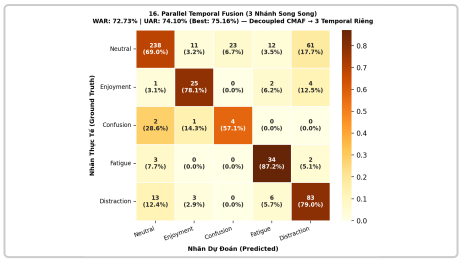


Hình 6b: Nhiễu Gaussian σ=0.1 (WAR: 77.65% | UAR: 77.27% • ΔUAR: -0.39%)

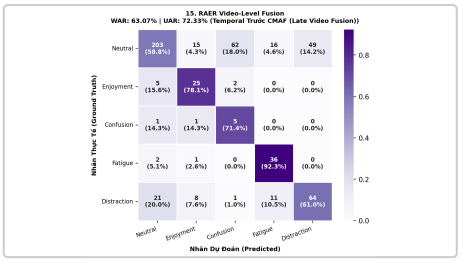
3.7 Đối So Sánh 3 Mô Thức Dung Hợp Không - Thời Gian (Spatio-Temporal Fusion Paradigms)



Hình 7a: Frame-Level (SOTA)
WAR: 77.08% | UAR: 77.66%



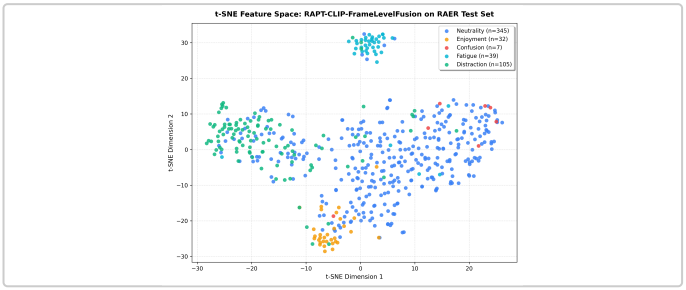
Hình 7b: Parallel Temporal (3 nhánh)
WAR: 72.73% | UAR: 74.10%



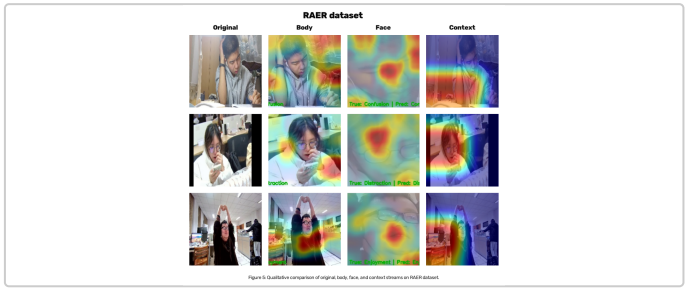
Hình 7c: Video-Level Fusion
WAR: 63.07% | UAR: 72.33%

Mô thức Dung hợp Không - Thời gian	Cơ chế Tương tác Liên luồng	Tham số Temporal	WAR / UAR (%)	Xếp hạng
Frame-Level Fusion (Hình 7a)	CMAF tương tác từng frame → Concat → Unified Temporal	**~4.7M (1 khối)**	**77.08% / 77.66%**	**SOTA ĐỀ XUẤT**
Parallel Temporal (Hình 7b)	3 khối Temporal độc lập (Face, Body, Context) → Concat muộn	~9.4M (3 khối)	**72.73% / 74.10%**	**-3.56% UAR**
Video-Level Fusion (Hình 7c)	Nén thời gian trước khi cho tương tác CMAF	~4.7M (1 khối)	**63.07% / 72.33%**	**-14.01% WAR**

4. TRỰC QUAN HÓA ĐẶC TRƯNG T-SNE & GRAD-CAM TRÊN RAER



Hình 8a: Không gian biểu diễn phân bố đặc trưng t-SNE của RAPT-CLIP Frame-Level Fusion

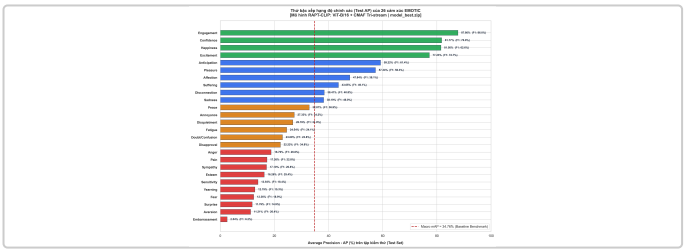


Hình 8b: Bản đồ Grad-CAM đa luồng (Face, Body, Context, Full Frame) trên RAER

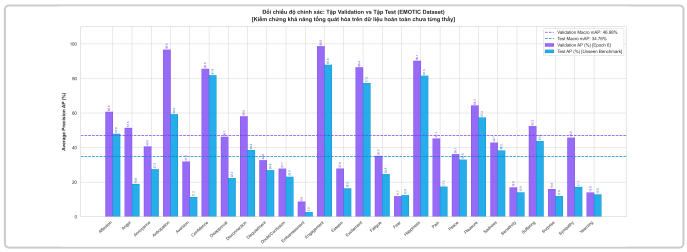
5. ĐÁNH GIÁ KHẢ NĂNG MỞ RỘNG ĐA MIỀN: BỘ DỮ LIỆU TỰ NHIÊN ĐA NHÃN EMOTIC (5,292 TEST IMAGES)

Phương pháp	mAP (%)	So với RAPT
Kosti et al. (CVPR'17)	27.38%	+7.38%
EmotiCon (CVPR'20)	33.10%	+1.66%
RAPT-CLIP (Ours)	**34.76%**	SOTA

Tham số	Cấu hình thực nghiệm
Backbone	CLIP ViT-B/16 (224 × 224, unfrozen)
Epochs / Batch	25 Epochs (Đỉnh Ep 6) | Batch Size: 16
Loss / Scheduler	Dynamic ASL (γ_=4.0, clip=0.05) | MultiStepLR
Fusion / Prompts	CMAF Tri-Stream (1536-d) | 8 learnable tokens

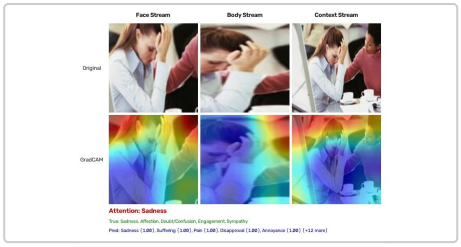


Hình 9a: Bảng xếp hạng Average Precision (AP) trên 26 lớp cảm xúc tập Test EMOTIC

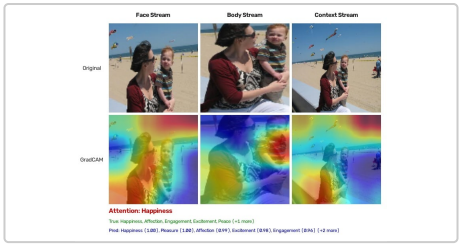


Hình 9b: So sánh tương quan Average Precision giữa Validation (46.98%) và Test (34.76%)

Trực Quan Hóa Grad-CAM Trên Tập Dữ Liệu Tự Nhiên EMOTIC



Hình 10a: Mẫu 1 (Mặt & Cảnh)



Hình 10b: Mẫu 2 (Hành vi Cơ thể)



Hình 10c: Mẫu 3 (Cảm xúc Phức hợp)

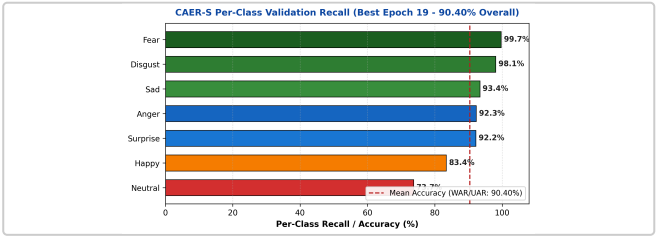
6. HUẤN LUYỆN VÀ ĐÁNH GIÁ TRÊN BỘ DỮ LIỆU CAER-S (STATIC IMAGES - 70,000 ẢNH)

Phương pháp	Năm	WAR / UAR
CAER-Net-S	2019	73.51%
EmotiCon	2020	77.00%
GRERN	2021	81.31%
EfficientFace	2021	85.87%
MA-Net	2021	88.42%
GLAMOR-Net	2023	89.88%
AGCD-Net	2023	90.65%
SAFER	2024	91.40%
RAPT-CLIP (Ours)	**Ep 19**	**90.40%**

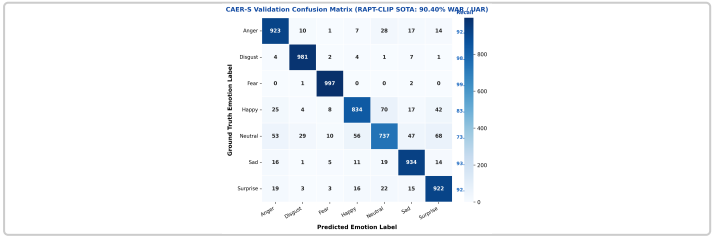
Tham số	Cấu hình thực nghiệm (caer_s_cmaf.sh)
Backbone	CLIP ViT-B/16 (224 × 224, unfrozen)
Epochs / Batch	20 Epochs (Đỉnh Ep 19) | Batch Size: 16
Hàm mất mát	LDAM Loss (s = 1.0, m_{max} = 0.5)
Bộ lấy mẫu	WeightedRandomSampler (Cân bằng batch)
Tốc độ học	Base: 2e-5 | ViT: 1e-6 | Prompt: 3e-4
Luồng dữ liệu	Triple-Stream: Face + Body + Masked Context
Dung hợp	Tridirectional Frame-Level CMAF (1536-d)
Temporal	Temporal Transformer (1 layer, Attn-Pool)
TTA	Horizontal Flip trên cả 3 luồng

ID	Cảm xúc	Đúng	Recall
0	Anger	923/1k	**92.30%**
1	Disgust	981/1k	**98.10%**
2	Fear	997/1k	**99.70%**
3	Happy	834/1k	**83.40%**
4	Neutral	737/1k	**73.70%**
5	Sad	934/1k	**93.40%**
6	Surprise	922/1k	**92.20%**
WAR / UAR		**6,328**	**90.40%**

True \ Pred	Ang	Dis	Fea	Hap	Neu	Sad	Sur
Anger	**923**	10	1	7	28	17	14
Disgust	4	**981**	2	4	1	7	1
Fear	0	1	**997**	0	0	2	0
Happy	25	4	8	**834**	70	17	42
Neutral	53	29	10	56	**737**	47	68
Sad	16	1	5	11	19	**934**	14
Surprise	19	3	3	16	22	15	**922**

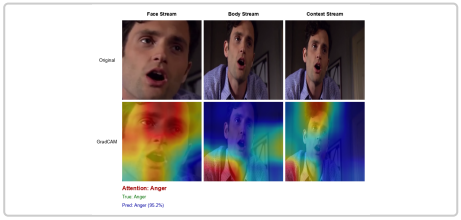


Hình 11a: Biểu đồ thanh Per-Class Recall trên 7 lớp cảm xúc CAER-S



Hình 11b: Bản đồ nhiệt Ma trận nhầm lẫn thực nghiệm trên 7,000 mẫu CAER-S

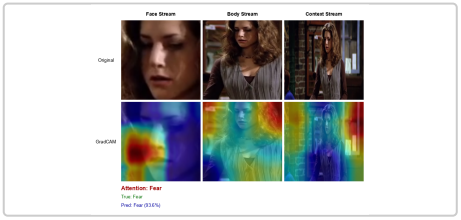
Trực Quan Hóa Grad-CAM Đa Luồng Trên CAER-S (Model: Caers-finetune.pth)



Hình 12a: Mẫu Anger (95.2%)



Hình 12b: Mẫu Happy (95.1%)



Hình 12c: Mẫu Fear (93.6%)