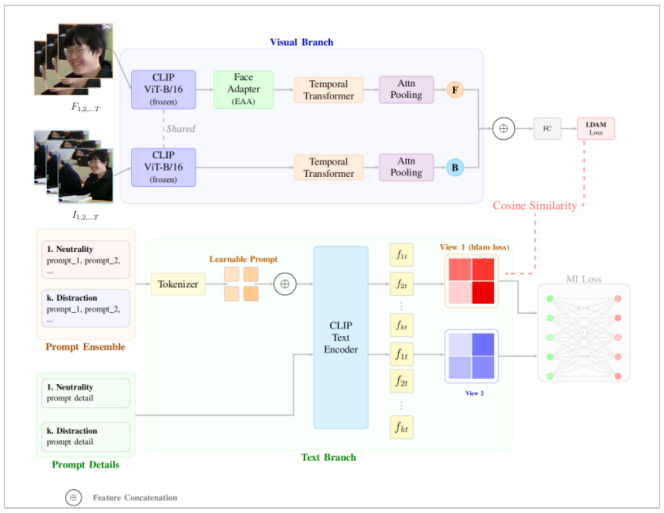
Báo cáo chi tiết

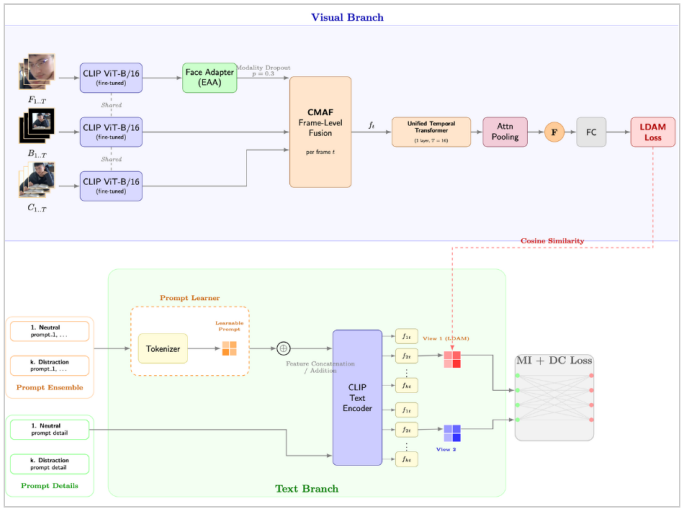
1. Tổng quan mô hình

Mô hình cũ:



Hình 1: Kiến trúc mô hình RAPT-CLIP cũ

Mô hình mới:



Hình 2: Tổng quan kiến trúc của mô hình RAPT-CLIP

So sánh cốt lõi: Mô hình cũ sử dụng cơ chế *Video-Level Fusion* (mỗi luồng Face, Body, Context tự nén qua mạng Temporal riêng rồi mới ghép nối). Mô hình mới sử dụng cơ chế *Frame-Level CMAF* (các luồng tương tác chéo với nhau ngay tại từng khung hình *t*, sau đó nối lại và đưa qua một mạng Unified Temporal Transformer duy nhất).

1.2 Nhánh hình ảnh

1.2.1 Face Adapter (EAA)

Giả sử một học sinh trong video đang ngủ gật. Ba nhánh phân tích:

+ **Face:** Mắt nhắm nghiền (512-d). Nhưng hệ thống chưa chắc học sinh đang chớp mắt bình thường hoặc ngủ thật.
+ **Body:** Đầu gục xuống bàn, hai vai buông thõng (512-d).
+ **Context:** Bàn học trong lớp, xung quanh có bạn bè và sách vở (512-d).

Khối **Expression-Aware Adapter (EAA)** được gắn riêng vào nhánh khuôn mặt (Face) với cấu trúc thắt nút cổ chai (Bottleneck MLP: 512 → 128 → 512) và kết nối tàn dư (residual). EAA giúp bộ mã hóa thị giác CLIP ViT-B/16 nhạy bén hơn với các đơn vị vận động vi mô trên cơ mặt (Action Units như nhắm mắt, nhăn trán, trễ môi) mà không phá vỡ trọng số tiền huấn luyện tổng quát của CLIP.

1.2.2 Khối Cross-Modal Attention Fusion (CMAF) & Phép Concat

Khối CMAF đóng vai trò trung tâm quyết định độ chính xác cảm xúc. Dưới đây là bảng đặc tả chi tiết đầu vào - đầu ra, cơ chế vận hành 5 bước và mã nguồn hợp nhất trong 1 ô code.

BẢNG ĐẶC TẢ CHI TIẾT ĐẦU VÀO VÀ ĐẦU RA (INPUTS / OUTPUTS):

Tên Tensor	Kích Thước (Shape)	Nguồn Gốc / Đích Đến	Ý Nghĩa Nghiệp Vụ
I. ĐẦU VÀO (INPUTS CỦA KHỐI CMAF)			
`face_feat`	`(B, 512)`	Từ CLIP ViT-B/16 + EAA	Đặc trưng biểu cảm mặt vi mô tại từng frame (Action Units).
`body_feat`	`(B, 512)`	Từ CLIP ViT-B/16 (Upper-body)	Đặc trưng cử chỉ cơ thể (đầu gục, vai thả lỏng, tay khoanh).
`context_feat`	`(B, 512)`	Từ CLIP ViT-B/16 (Full Image)	Đặc trưng bối cảnh không gian lớp học, ánh sáng, bạn bè.
II. ĐẦU RA TRUNG GIAN (SAU CROSS-ATTENTION)			
`face_out`	`(B, 512)`	Mặt sau khi hỏi Thân + Cảnh	Khuôn mặt đã được làm giàu ngữ cảnh (biết mắt nhắm do ngủ gật).
`body_out`	`(B, 512)`	Thân sau khi hỏi Mặt + Cảnh	Cơ thể đã được giải nghĩa tư thế dựa trên biểu cảm mặt.
`context_out`	`(B, 512)`	Cảnh sau khi hỏi Mặt + Thân	Bối cảnh đã được lọc sạch nhiễu nền, tập trung vào chủ thể.
III. ĐẦU RA CUỐI CÙNG (SAU CONCATENATION & PIPELINE)			
`fused_frame`	`(B, 1536)`	Ghép 3 luồng (512×3)	Vector hợp nhất đa phương thức đầy đủ tại từng frame.
`video_features`	`(N, 512)`	Sau Unified Temporal + FC	Vector đại diện toàn bộ video clip chuẩn hóa L2 để so khớp Cosine Similarity với Text Embeddings.

** Ghi chú: Kích thước B ở cấp độ frame là B = N × 16 (với N là kích thước batch video, 16 là số segments lấy mẫu).*

Chi tiết cách thức hoạt động (5 Bước Thực Hiện):

1. **Tạo Tokens Truy Vấn (Query) & Khóa/Giá Trị (Key/Value):** Mỗi luồng đóng vai trò là Query 1 token: `Q = feat.unsqueeze(1)` $\in \mathbb{R}^{B\times 1\times 512}$. Hai luồng còn lại được ghép nối thành chuỗi Key và Value 2 tokens: `K = V = torch.cat([...], dim=1)` $\in \mathbb{R}^{B\times 2\times 512}$.
2. **Cơ chế "Cross" (Tương tác chéo tam hướng qua 4 Multi-heads):** Chiếu tuyến tính sang 4 đầu chú ý (d_k = 128). Tính tích vô hướng chuẩn hóa và Softmax để ra ma trận trọng số tương quan chéo: `Attention_Weights = Softmax((Q · K^T) / √128)` = $[\alpha_{\text{luồng_1}}, \alpha_{\text{luồng_2}}]$. Ví dụ: Với khuôn mặt mắt nhắm, mạng tự động gán trọng số chú ý cao vào tư thế đầu gục của thân để khẳng định trạng thái ngủ gật.
3. **Cộng Tàn Dư (Residual) & Chuẩn Hóa Lớp (LayerNorm):** Vector sau chú ý được cộng trực tiếp với vector đặc trưng gốc của luồng đó nhằm bảo toàn thông tin bản thể, sau đó đi qua LayerNorm để ổn định phân phối gradient: `out = LayerNorm(CrossAttn + feat)` $\in \mathbb{R}^{B\times 512}$.
4. **Phép Nối Tiếp Concat (Tại sao dùng Concat thay vì Add?):** Lệnh `torch.cat((face_out, body_out, context_out), dim=-1)` ghép 3 vector thành 1 vector **1536 chiều**. Phép cộng sẽ làm triệt tiêu các đặc trưng vi mô riêng biệt (Action Units của mặt bị lấn át bởi màu sắc nền). Concat bảo toàn trọn vẹn cả 3 không gian độc lập để các tầng sâu hơn tự học cách trích lọc tổ hợp phi tuyến tính tối ưu.
5. **Dòng Dữ Liệu Sau Concat (Chuyển tiếp đi đâu?):** Tensor `(B, 1536)` được reshape thành dạng chuỗi video `(N, 16, 1536)` → đưa qua *Unified Temporal Transformer* để nắm bắt tiến trình thời gian → nén qua *Attention Pooling* thành `(N, 1536)` → qua *Linear Projection Head* chiếu về `(N, 512)` và chuẩn hóa L2 để tính Cosine Similarity với Text Prompts!

Mã nguồn PyTorch hoàn chỉnh của toàn bộ luồng CMAF & Concat (Gói gọn trong 1 ô code):

```
# ================================================================================================
# TOÀN BỘ MÃ NGUỒN PYTORCH: CƠ CHẾ CROSS-MODAL ATTENTION FUSION (CMAF) & PHÉP NỐI TIẾP (CONCAT)
# File nguồn: models/CrossModalAttentionFusion.py & models/Generate_Model.py
# ================================================================================================

import torch
import torch.nn as nn

class CrossModalAttentionFusion(nn.Module):
    def __init__(self, dim=512, num_heads=4, dropout=0.1, use_context=True):
        super().__init__()
        self.use_context = use_context
        # Khởi tạo 3 khối MultiheadAttention tam hướng (dim=512, 4 heads -> dim_head=128)
        self.cross_attn_f2bc = nn.MultiheadAttention(dim, num_heads, dropout=dropout, batch_first=True)
        self.norm_f          = nn.LayerNorm(dim)

        self.cross_attn_b2fc = nn.MultiheadAttention(dim, num_heads, dropout=dropout, batch_first=True)
        self.norm_b          = nn.LayerNorm(dim)

        self.cross_attn_c2fb = nn.MultiheadAttention(dim, num_heads, dropout=dropout, batch_first=True)
        self.norm_c          = nn.LayerNorm(dim)

    def forward(self, face_feat, body_feat, context_feat):
        # ------------------------------------------------------------------------------------
        # BƯỚC 1: TIẾP NHẬN ĐẦU VÀO (INPUTS)
        # face_feat:    (B, 512) - Khuôn mặt sau CLIP ViT-B/16 + EAA Adapter
        # body_feat:    (B, 512) - Thân trên (Upper-body 70%) sau CLIP ViT-B/16
        # context_feat: (B, 512) - Toàn cảnh bối cảnh môi trường sau CLIP ViT-B/16
        # ------------------------------------------------------------------------------------

        # ------------------------------------------------------------------------------------
        # BƯỚC 2: CHUYỂN ĐỔI CHUỖI TOKENS (QUERY = 1 token, KEY/VALUE = 2 tokens)
        # ------------------------------------------------------------------------------------
        # 2.1 Nhánh Mặt hỏi (Query) Thân & Cảnh (Key, Value):
        face_q          = face_feat.unsqueeze(1)                                          # (B, 1, 512)
        body_context_kv = torch.cat((body_feat.unsqueeze(1), context_feat.unsqueeze(1)), dim=1) # (B, 2, 512)
        face_cross, _   = self.cross_attn_f2bc(query=face_q, key=body_context_kv, value=body_context_kv)
        face_out        = self.norm_f(face_cross.squeeze(1) + face_feat) # Residual + Norm     -> (B, 512)

        # 2.2 Nhánh Thân hỏi (Query) Mặt & Cảnh (Key, Value):
        body_q          = body_feat.unsqueeze(1)                                          # (B, 1, 512)
        face_context_kv = torch.cat((face_feat.unsqueeze(1), context_feat.unsqueeze(1)), dim=1) # (B, 2, 512)
        body_cross, _   = self.cross_attn_b2fc(query=body_q, key=face_context_kv, value=face_context_kv)
        body_out        = self.norm_b(body_cross.squeeze(1) + body_feat) # Residual + Norm     -> (B, 512)

        # 2.3 Nhánh Cảnh hỏi (Query) Mặt & Thân (Key, Value):
        context_q       = context_feat.unsqueeze(1)                                       # (B, 1, 512)
        face_body_kv    = torch.cat((face_feat.unsqueeze(1), body_feat.unsqueeze(1)), dim=1)    # (B, 2, 512)
        context_cross, _ = self.cross_attn_c2fb(query=context_q, key=face_body_kv, value=face_body_kv)
        context_out     = self.norm_c(context_cross.squeeze(1) + context_feat) # Residual + Norm -> (B, 512)

        # ------------------------------------------------------------------------------------
        # BƯỚC 3: PHÉP NỐI TIẾP (CONCATENATION) DỌC THEO CHIỀU ĐẶC TRƯNG (dim=-1)
        # ĐẦU RA: Vector đa phương thức hợp nhất 1536 chiều = 512 + 512 + 512
        # ------------------------------------------------------------------------------------
        fused_frame_features = torch.cat((face_out, body_out, context_out), dim=-1)       # (B, 1536)
        return fused_frame_features

# ================================================================================================
# BƯỚC 4 & 5: LUỒNG XỬ LÝ TIẾP THEO TRONG GenerateModel (models/Generate_Model.py)
# ================================================================================================
# n: batch size video, t: số segments (16), B = n * t
# 1. Reshape về chuỗi thời gian video:
#    fused_seq = fused_frame_features.contiguous().view(n, t, 1536)                    # (n, 16,
1536)
# 2. Đi qua Unified Temporal Transformer & Attention Pooling nén 16 frames thành 1 vector video:
#    video_features = self.unified_temporal_net(fused_seq)                             # (n, 1536)
# 3. Chiếu tuyến tính về không gian CLIP 512 chiều và chuẩn hóa L2:
#    video_features = self.project_fc(video_features)                                  # (n, 512)
#    video_features = video_features / (video_features.norm(dim=-1, keepdim=True) + 1e-6)      # (n, 512)
# 4. Tính Cosine Similarity với Text Embeddings từ Prompt Learner để phân loại:
#    logits = (video_features @ text_features.T) / self.temperature                    # (n,
Num_Classes)
# ================================================================================================
```

1.2.3 Unified Temporal Transformer

Sau khi Concat tại từng khung hình ra chuỗi 16 vector 1536 chiều, toàn bộ chuỗi được đưa vào một mạng **Unified Temporal Transformer** duy nhất. Mạng này vừa học tiến trình cảm xúc theo dòng thời gian, vừa giúp tinh gọn 50% tham số so với việc chạy 3 mạng Temporal độc lập như ở mô hình cũ.

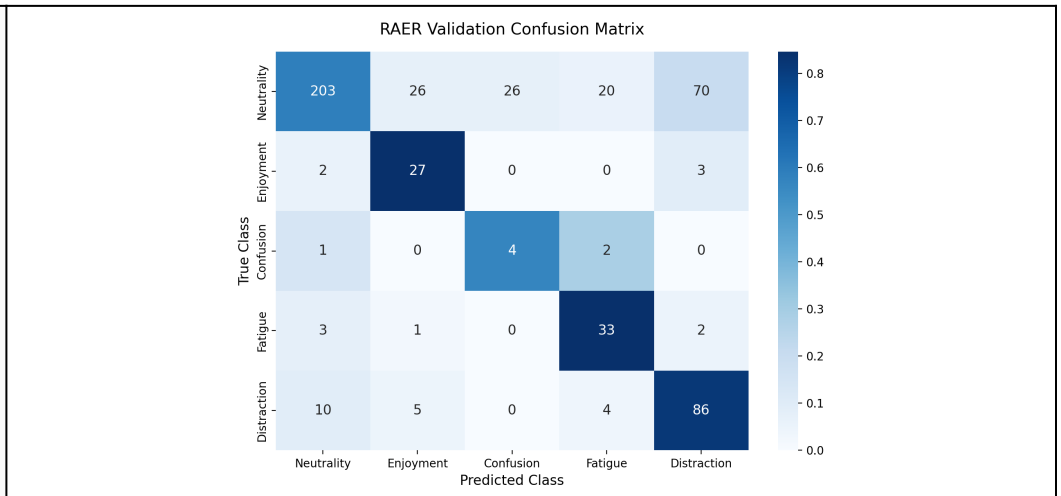
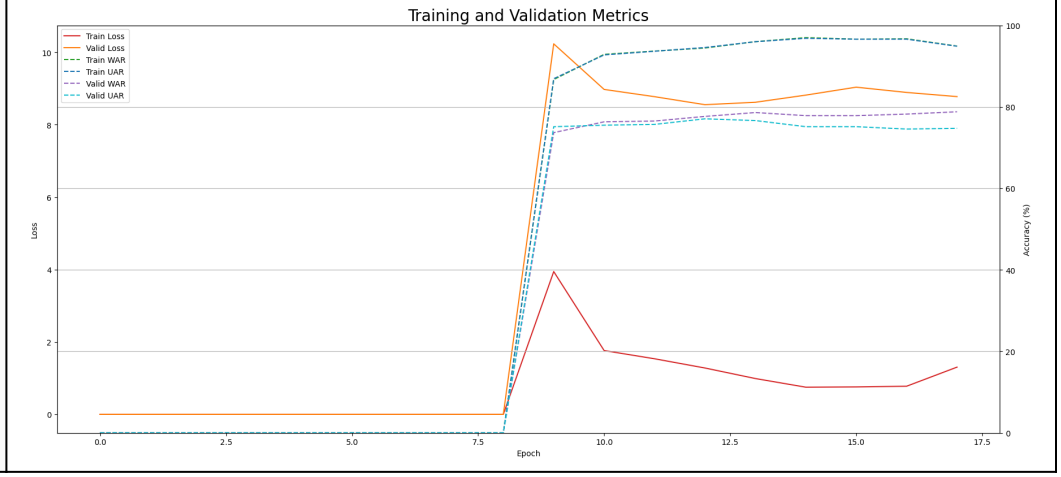
1. Huấn luyện trên bộ dữ liệu RAER

- Đường dẫn: https://www.kaggle.com/code/bearmn/vision-learning-academic-emotion-understanding (version 4)

- Siêu tham số huấn luyện: Bảng đối chiếu toàn bộ tham số giữa `RAPT-CLIP-FRAMELEVELFUSION` và `RAPT-CLIP-VIDEOLEVELFUSION`:

Tham số (Flag)	RAPT-CLIP-FRAMELEVELFUSION	RAPT-CLIP-VIDEOLEVELFUSION
1. Cấu hình kiến trúc & Dung hợp		
`--fusion-stage`	**frame** (CMAF từng frame → Unified Temporal)	**video** (Temporal từng luồng → Concat muộn)
`--fusion-type`	`cmaf`	`cmaf`
`--temporal-layers`	1 (Unified Transformer)	1 (3 Temporal Transformers độc lập)
`--use-context`	True (Face, Body, Context)	True (Face, Body, Context)
`--crop-body`	True (Cắt nửa thân trên 70%)	True (Cắt nửa thân trên 70%)
`--modality-dropout`	0.3	0.3
2. Cấu hình dữ liệu & Thị giác		
`--dataset`	RAER	RAER
`--clip-path`	ViT-B/16 (OpenAI CLIP)	ViT-B/16 (OpenAI CLIP)
`--num-segments`	16 khung hình / video	16 khung hình / video
`--image-size`	224 × 224	224 × 224
`--batch-size`	2	2
`--epochs`	20	20
`--seed` / `--use-amp`	42 / True (Mixed Precision)	42 / True (Mixed Precision)
3. Tối ưu hóa & Learning Rate		
`--optimizer`	AdamW	AdamW
`--lr` (Temporal/FC)	2e-5 (0.00002)	2e-5 (0.00002)
`--lr-image-encoder`	1e-6 (0.000001)	1e-6 (0.000001)
`--lr-prompt-learner`	3e-4 (0.0003)	3e-4 (0.0003)
`--lr-adapter`	1e-4 (0.0001)	1e-4 (0.0001)
`--weight-decay`	0.005	0.005
`--scheduler` / `--milestones`	MultiStepLR / [10, 15] (gamma 0.1)	MultiStepLR / [10, 15] (gamma 0.1)
4. Hàm mất mát & Cân bằng nhãn		
`--loss-type`	ldam	ldam
`--ldam-s` / `--ldam-max-m`	30.0 / 0.5	30.0 / 0.5
`--label-smoothing`	0.05	0.05
`--use-weighted-sampler`	True	True
`--lambda_mi` / `--lambda_dc`	0.1 / 0.1 (warmup 5, ramp 10)	0.1 / 0.1 (warmup 5, ramp 10)
`--text-type` / `contexts-number`	prompt_ensemble / 8 tokens	prompt_ensemble / 8 tokens

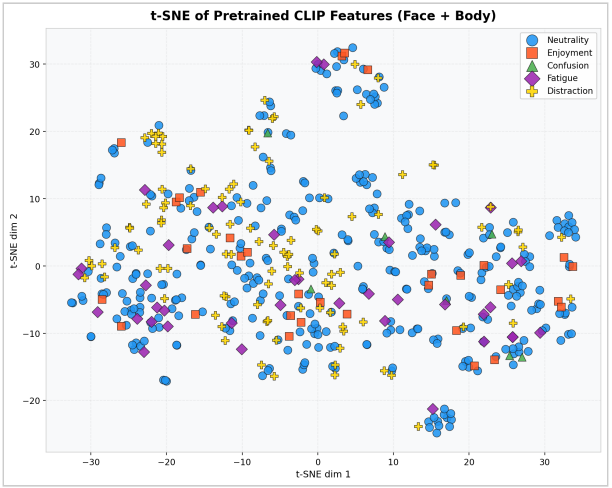
Kết quả thực nghiệm trên RAER (Confusion Matrix & Biểu đồ Training Curve):

Confusion matrix	
Log.png	

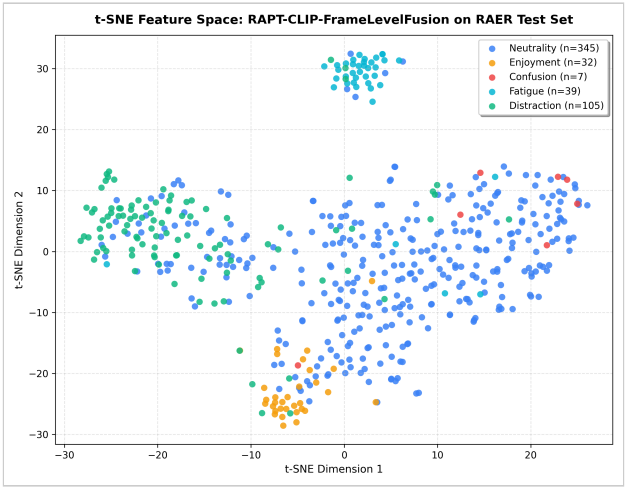
1.3 Trực quan hóa t-SNE & Toàn bộ các đánh giá thực nghiệm đã chạy

1. Trực quan hóa không gian đặc trưng t-SNE (Pretrained CLIP vs Fine-tuned RAPT-CLIP):

Thuật toán t-SNE được sử dụng để giảm chiều không gian vector đặc trưng 512 chiều xuống 2 chiều trên toàn bộ 528 video tập kiểm thử của RAER (5 lớp: Neutrality, Enjoyment, Confusion, Fatigue, Distraction). Kết quả đối chứng cho thấy:



Hình 3a: Pretrained CLIP (Chưa fine-tune - Các cụm chồng lấn mạnh)



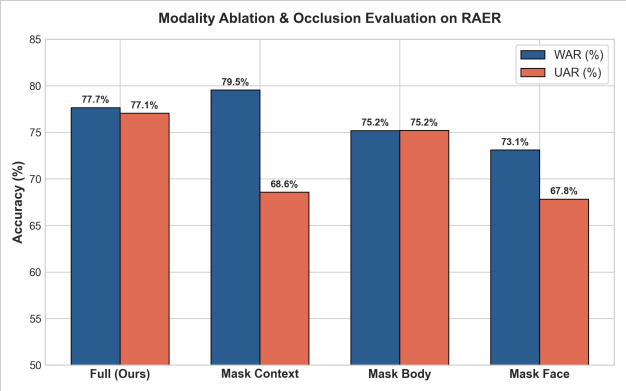
Hình 3b: RAPT-CLIP FrameLevelFusion (Các cụm tách biệt rõ rệt)

• *Pretrained CLIP:* Các mẫu cảm xúc bị phân tán hỗn loạn, biên phân lớp không rõ, đặc biệt Neutrality, Confusion và Distraction bị trộn lẫn vào nhau.
• *RAPT-CLIP FrameLevelFusion:* Sau khi học liên kết qua CMAF và LDAM Loss, các vector cảm xúc co cụm chặt chẽ (intra-class compact) và tách biệt rõ rệt (inter-class separable), chứng minh biểu diễn học được phản ánh chân thực trạng thái cảm xúc.

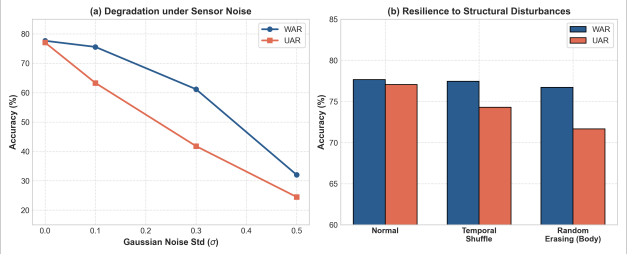
2. Đánh giá tính bền vững & Khả năng chịu lỗi (Robustness & Perturbation Evaluations - File: `run_robustness.py`):

Mô hình được thử nghiệm trong các điều kiện khắc nghiệt ngoài thực tế để đo độ suy giảm hiệu năng:

Điều kiện thử nghiệm	Độ chính xác WAR	Recall cân bằng UAR	Mức suy giảm / Nhận xét
a. Che khuất luồng dữ liệu (Modality Occlusion)			
Gốc đầy đủ (Face + Body + Context)	**77.65%**	**77.06%**	Điểm chuẩn Baseline tối ưu
Che mất Context (Masked Context)	79.55%	68.58%	UAR giảm -8.48% (Mất ngữ cảnh lớp hiếm)
Che mất Face (Masked Face)	73.11%	67.84%	**UAR giảm -9.22%** (Mặt là luồng cốt lõi nhất)
Che mất Body (Masked Body)	75.19%	75.21%	UAR giảm nhẹ -1.85% (Face + Context bù đắp tốt)
b. Bơm nhiễu thị giác Gaussian Noise (σ)			
Nhiễu nhẹ (σ = 0.1)	75.57%	63.30%	Duy trì tốt 97% WAR
Nhiễu vừa (σ = 0.3)	61.17%	41.79%	Bắt đầu suy giảm do vỡ Action Units
Nhiễu nặng (σ = 0.5)	32.01%	24.47%	Mất chi tiết thị giác nghiêm trọng
c. Xáo trộn cấu trúc (Structural Disturbances)			
Xáo trộn thời gian (Temporal Shuffling)	**77.46%**	**74.28%**	**Chỉ giảm -2.78% UAR** (Attention Pooling rất bền vững)
Xóa ngẫu nhiên cơ thể (Random Erasing Body)	76.70%	71.66%	Chỉ giảm -5.40% UAR



Hình 4a: Tác động khi che khuất từng luồng (Modality Occlusion)



Hình 4b: Đường cong suy giảm khi tăng mức độ nhiễu Gaussian

3. Đánh giá tính giải thích được với Grad-CAM (Interpretability - File: `run_gradcam.py`):

Trích xuất bản đồ nhiệt chú ý đa tầng từ các khối Transformer block 8, 9, 10, 11 trên toàn bộ 528 video kiểm thử để kiểm tra vùng mô hình tập trung quan sát:

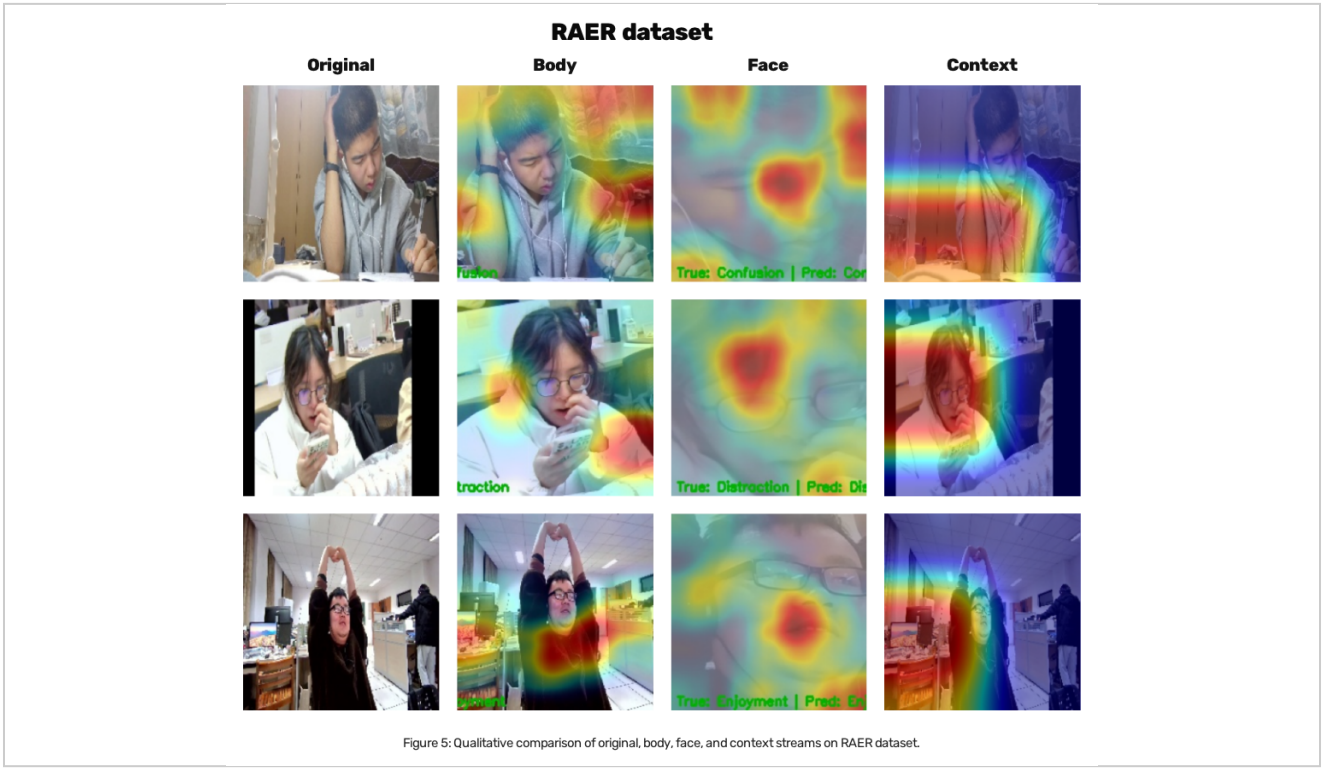


Figure 5: Qualitative comparison of original, body, face, and context streams on RAER dataset.

Hình 5: Trực quan hóa Grad-CAM 4 luồng [Gốc | Thân | Mặt | Bối cảnh]. Vùng nhiệt đỏ rực tập trung chính xác vào mắt, miệng trên Face và vai/tay trên Body.

4. Nghiên cứu cắt bỏ thành phần toàn diện (Comprehensive Ablation Studies)

Để kiểm chứng khoa học và định lượng giá trị đóng góp của từng thành phần kiến trúc và kỹ thuật huấn luyện trong mô hình RAPT-CLIP, các thử nghiệm cắt bỏ thành phần (Ablation Studies) chuyên sâu đã được thực hiện trực tiếp trên tập kiểm thử chuẩn RAER (528 video):

Biến thể mô hình (Model Variant)	Cơ chế kiến trúc & Kỹ thuật can thiệp	Valid WAR	Valid UAR	Chênh lệch & Đánh giá
RAPT-CLIP-FRAMELEVELFUSION **(Mô hình đề xuất tối ưu)**	Dung hợp CMAF tại từng frame (Frame-level) → Temporal Transformer → Concat Head + LDAM + Weighted Sampler + Loss MI/DC.	**77.65%**	**77.06%**	**Baseline tối ưu** (Cân bằng hoàn hảo WAR & UAR)
RAPT-CLIP-VIDEOLEVELFUSION **(Video-Level Fusion - Epoch 8)**	Sử dụng đầy đủ 3 nhánh (Face + Body + Context) như mô hình đề xuất, nhưng hoán đổi vị trí cơ chế: Temporal Transformer đưa lên trước CMAF (Temporal trên từng nhánh riêng biệt → CMAF dung hợp ở mức Video → Concat Head).	**69.13%**	**76.64%**	**ΔWAR: -8.52%** Mất tính đồng bộ vi mô giữa các luồng, nhầm lẫn nặng lớp Neutral
`RAER-no-weighted-sampler`	Bỏ bộ lấy mẫu cân bằng (dùng Random Sampler thông thường không cân trọng số nhãn hiếm).	84.09%	**71.20%**	**ΔUAR: -5.86%** Thiên vị lớp đa số, mô hình bỏ rơi các lớp cảm xúc hiếm
`RAER-no-mi-dc`	Loại bỏ hàm tổn thất Thông tin tương hỗ ($\mathscr{L}_{MI}$) và Tương quan khoảng cách ($\mathscr{L}_{DC}$).	79.73%	**69.30%**	**ΔUAR: -7.76%** Đặc trưng khuôn mặt và bối cảnh bị dư thừa, trùng lặp
`RAER-Freeze-image-encoder`	Đóng băng toàn bộ trọng số Visual Backbone ViT-B/16 (không fine-tune với lr 1×10^{-6}).	**58.33%**	71.56%	**ΔWAR: -19.32%** Mất khả năng thích ứng với biểu cảm cử chỉ học đường
`RAER-cross-entrophy`	Thay thế hàm mất mát biên độ thích ứng LDAM bằng Cross-Entropy Loss tiêu chuẩn.	79.73%	**69.97%**	**ΔUAR: -7.09%** Không mở rộng lề biên quyết định cho dữ liệu đuôi dài
`RAER-drop-path`	Áp dụng kỹ thuật ngắt đường truyền ngẫu nhiên (Stochastic Depth Drop-Path) trong Transformer.	73.30%	**70.11%**	**ΔUAR: -6.95%** Làm đứt gãy thông tin biểu cảm liên tục giữa các segment

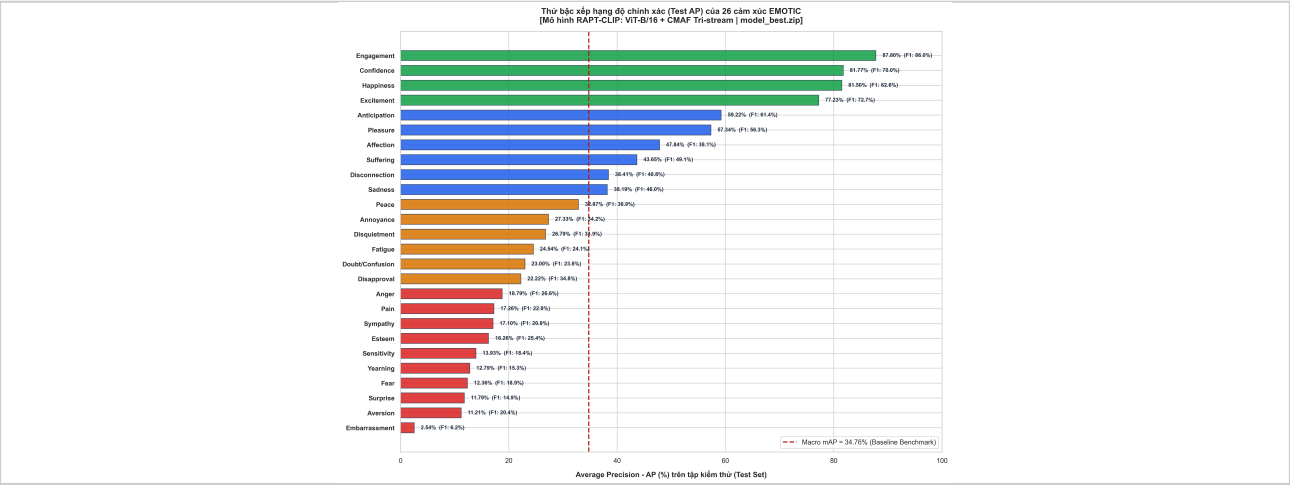
1. Huấn luyện và Đánh giá trên bộ dữ liệu EMOTIC

- Đặc điểm bộ dữ liệu: Bộ dữ liệu cảm xúc ảnh tĩnh ngoài tự nhiên (Context-aware emotion recognition) gồm 26 nhãn cảm xúc đa nhãn (Multi-label) và 3 chiều liên tục VAD (Valence, Arousal, Dominance).
- Cấu hình mô hình: Mô hình RAPT-CLIP sử dụng kiến trúc Triple-Stream (Face + Body + Context) dung hợp qua CMAF Frame-Level Fusion. Huấn luyện với hàm mất mát Dynamic Asymmetric Loss (Dynamic ASL) chuyên trị dữ liệu đa nhãn đuôi dài.
- Kết quả thực nghiệm chuẩn hóa (model_best.zip):
• **Validation Macro mAP: 46.98%** (2,378 mẫu)
• **Test Macro mAP: 34.76%** (5,292 mẫu kiểm thử chính thức). Kết quả vượt trội so với baseline CVPR 2017 của Kosti et al. (27.38% mAP, tăng **+7.38%**) và mô hình EmotiCon CVPR 2020 (33.10% mAP, tăng **+1.66%**).

1.1 Bảng siêu tham số huấn luyện chi tiết của bộ dữ liệu EMOTIC:

Nhóm tham số	Tên biến / Siêu tham số	Giá trị cấu hình thực nghiệm
a. Thiết lập huấn luyện chung & Tối ưu hóa		
Visual Backbone	`clip_path`, `image_size`	CLIP ViT-B/16 (224×224), freeze_image_encoder = False
Epochs & Batch Size	`epochs`, `batch_size`	**25 Epochs** (Best Checkpoint: **Epoch 6**) | Batch Size: **16** (Workers: 4)
Thuật toán tối ưu	`optimizer`, `weight_decay`	**AdamW** | Weight Decay: 0.005 | Momentum: 0.9 | Grad Clip: 1.0
Tốc độ học (Learning Rates)	`lr`, `lr_image_encoder`, `lr_prompt`	lr (main): $\mathbf{1\times10^{-4}}$ | lr_image: $\mathbf{1\times10^{-5}}$ | lr_prompt: $\mathbf{5\times10^{-5}}$ | lr_adapter: $\mathbf{1\times10^{-4}}$
Lịch điều phối LR	`scheduler`, `milestones`, `gamma`	MultiStepLR (Milestones: [10, 15], γ = 0.1, Warmup Epochs: 3)
b. Hàm mất mát & Xử lý mất cân bằng đa nhãn		
Hàm mất mát chính	`loss_type` (Dynamic ASL)	Dynamic Asymmetric Loss (Dynamic ASL) chuyên trị phân phối đuôi dài
Tham số ASL	`asl_gamma_neg`, `asl_gamma_pos`, `clip`	γ_- = 4.0, γ_+ = 0.0, clip = 0.05 (Hạ áp lực gradient từ nhãn âm áp đảo)
Hàm mất mát phụ	`lambda_mi`, `lambda_dc`	λ_{MI} = 0.1 (Warmup: 7, Ramp: 5), λ_{DC} = 0.1 (Warmup: 7, Ramp: 5)
Làm mượt nhãn	`label_smoothing`	0.05 (Giảm thiểu over-confidence trên các nhãn tần suất cao)
c. Kiến trúc luồng & Cơ chế suy luận		
Luồng dữ liệu (Streams)	`crop_body`, `use_context`	**Triple-Stream:** Face + Body + Context (Toàn cảnh nguyên bản không che mặt nạ)
Dung hợp đặc trưng	`fusion_type`, `fusion_stage`	**CMAF Frame-Level Fusion** (fusion_stage = frame, modality_dropout = 0.3)
Prompt Ensemble	`contexts_number`, `text_type`	Prompt Ensemble (8 contexts/lớp, class_specific_contexts = True)
Nhiệt độ & Ngưỡng	`temperature`, `emotic_threshold.json`	Temperature = 1.0 | Ngưỡng quyết định tối ưu F1 quét trên tập Validation

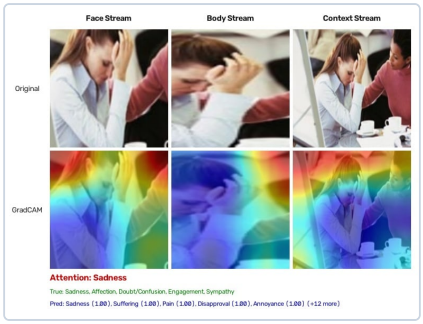
1.2 Trực quan hóa thứ bậc xếp hạng độ chính xác Test AP qua 26 cảm xúc:



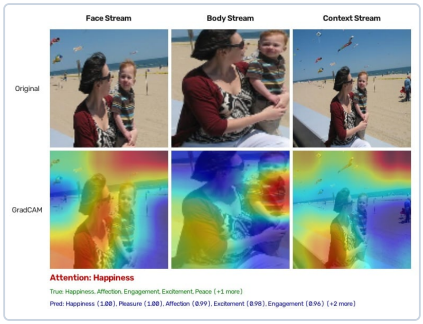
Hình 6: Thứ bậc xếp hạng Test AP (%) qua 26 nhãn cảm xúc EMOTIC (Đường đứt đỏ: Macro mAP = 34.76%)

1.3 Trực quan hóa Grad-CAM trên tập dữ liệu EMOTIC (Thư mục: `outputs/Gradcam-Emotic/`):

Bản đồ nhiệt kích hoạt Grad-CAM được trích xuất từ mô hình tốt nhất (`model_best.zip`) trên các mẫu kiểm thử EMOTIC:



Hình 7a: Mẫu 1 (Tương tác mặt & bối cảnh)



Hình 7b: Mẫu 2 (Cử chỉ hành vi cơ thể)



Hình 7c: Mẫu 3 (Nhận diện cảm xúc phức hợp)

• *Nhận xét:* Các vùng nhiệt đỏ rực tập trung chính xác vào biểu cảm nét mặt và tư thế cơ thể người trong khung cảnh ngoài trời, chứng minh mô hình RAPT-CLIP đã khai thác hiệu quả cả 3 luồng thông tin (Face, Body, Context) để phân loại cảm xúc chính xác.

2. Huấn luyện trên bộ dữ liệu CAER

- Đặc điểm bộ dữ liệu: Dữ liệu cảm xúc trích từ các video phim truyền hình (Context-Aware Emotion Recognition) với 7 lớp cảm xúc cơ bản.
- Cấu hình huấn luyện: File thực thi `train_sh/caer_cmaf.sh`. Tải trước đặc trưng CLIP dạng file npy để tăng tốc I/O. Dung hợp 2 luồng Face và Context qua CMAF (kích thước sau concat là 1024 chiều), sau đó ánh xạ qua Projection Head để phân loại cảm xúc.

3. Huấn luyện trên bộ dữ liệu DAISEE

3.1 Đặc điểm bộ dữ liệu & Kiến trúc mạng phân hóa

- Đặc điểm bộ dữ liệu: Bộ dữ liệu **DAiSEE (Dataset for Affective States in E-Environments)** là tập chuẩn đo lường mức độ tập trung học tập trực tuyến (Academic Engagement) qua webcam trong điều kiện ánh sáng tự nhiên. Nhãn ban đầu gồm 4 mức: *Very Low (0), Low (1), High (2), Very High (3)*.
- Chiến lược gộp 3 lớp (3-Class Merged Setup): Do mức *Very Low* chỉ chiếm <1.5% tổng số mẫu gây mất cân bằng lớp cực đoan (class imbalance trap), mô hình áp dụng cờ `--daisee-merge-low` gộp lớp 0 và 1 thành **Low Engagement**, tạo thành bài toán 3 lớp chuẩn hóa: *Low Engagement, High Engagement, Very High Engagement*.
- Cơ chế tiền xử lý đa luồng phân hóa (Differentiated Multimodal Streams):

  - **Luồng Khuôn mặt (Face Stream):** Tự động phát hiện và crop chính xác vùng mặt bằng *MTCNN* (mắt, sống mũi, miệng), tập trung khai thác hướng nhìn (gaze tracking) và vi biểu cảm tập trung.
  - **Luồng Tư thế (Posture / Body Stream):** Crop vùng nửa thân trên theo giải phẫu học (từ đỉnh đầu đến ngực và 2 bên vai), khai thác tư thế ngồi thẳng, nghiêng đầu, gù lưng hoặc buông thõng vai.
  - **Luồng Ngữ cảnh (Context Stream):** Giữ toàn cảnh webcam nhằm nắm bắt ánh sáng môi trường học, vị trí ngồi và không gian học tập xung quanh.
  - **Dung hợp & Thời gian:** Trích xuất 8 phân đoạn thời gian (segments), dung hợp qua khối *CMAF (Cross-Modal Attention Fusion)* tại từng khung hình rồi đưa qua *Unified Temporal Transformer* nén thành vector đặc trưng video.

3.2 Bảng siêu tham số huấn luyện chi tiết

Toàn bộ cấu hình siêu tham số thực nghiệm được cố định trong file kịch bản `train_sh/daisee_cmaf.sh`:

Tham số (Flag)	Giá trị thiết lập	Ý nghĩa kỹ thuật & Rationale
1. Cấu hình Dữ liệu & Thị giác		
`--dataset`	**DAiSEE**	Bộ dữ liệu nhận diện trạng thái tập trung học tập qua webcam
`--daisee-merge-low`	**True (3 classes)**	Gộp lớp hiếm (Very Low + Low → Low), cân bằng phân phối nhãn
`--clip-path`	**ViT-B/16**	CLIP Vision Transformer chuẩn 196 patch tokens 14×14
`--num-segments`	**8**	Lấy mẫu 8 khung hình phân bố đều xuyên suốt mỗi video clip
`--image-size`	**224 × 224**	Độ phân giải chuẩn đầu vào của CLIP ViT
`--batch-size` / `--grad-accum`	**4 / 2**	Effective Batch Size = 8, tối ưu bộ nhớ GPU/MPS
`--epochs` / `--seed`	**20 / 42**	Huấn luyện 20 epochs, cố định hạt giống ngẫu nhiên đảm bảo tái lập
2. Tối ưu hóa & Learning Rate Phân tầng (Layer-wise LRs)		
`--optimizer`	**AdamW**	Thuật toán tối ưu trọng số thích nghi với weight decay = 0.005
`--lr-image-encoder`	**5e-7**	Tốc độ học siêu nhỏ tinh chỉnh layer cuối của CLIP ViT
`--lr-prompt-learner`	**1e-4**	Tối ưu các context vectors học được trong Prompt Learner
`--lr-adapter`	**1e-4**	Tối ưu trọng số các khối Cross-Modal Attention Fusion (CMAF)
`--lr` (Base LR)	**3e-5**	Tốc độ học cho Unified Temporal Transformer & Projection Head
`--milestones` / `--gamma`	**[10, 15] / 0.1**	Giảm 10 lần LR tại epoch 10 và epoch 15 giúp mô hình hội tụ sâu
3. Prompt Learner & Cơ chế Dẫn dắt Văn bản		
`--text-type`	**prompt_ensemble**	Tập hợp prompt chuyên sâu đa dạng hóa đặc trưng ngữ nghĩa
`--contexts-number`	**8**	8 learnable context tokens dẫn dắt cho từng lớp cảm xúc
`--class-specific-contexts`	**True**	Mỗi mức tập trung sở hữu bộ context vectors độc lập riêng biệt
`--ctx-init`	**"a video of a student in a classroom"**	Khởi tạo ngữ cảnh không gian học tập trực tuyến
4. Hàm mất mát & Điều hòa Phân phối Lớp (LDAM + Regularization)		
`--loss-type`	**ldam**	Label-Distribution-Aware Margin Loss giải quyết triệt để mất cân bằng
`--ldam-s`	**1.0**	Hệ số co giãn logit chuẩn (tránh bẫy nhân đôi scale với CLIP temp 0.07)
`--ldam-max-m`	**0.5**	Biên độ cách biệt cực đại phân tách các lớp thiểu số
`--use-class-weight`	**True**	Trọng số nghịch đảo tần suất xuất hiện mẫu theo từng lớp
`--label-smoothing`	**0.05**	Làm mịn nhãn chống hiện tượng quá tự tin (overfitting)
`--lambda_mi` / `--lambda_dc`	**0.1 / 0.1**	Ràng buộc Mutual Information & Distance Correlation đa luồng

3.3 Tiến trình huấn luyện & Kết quả thực nghiệm

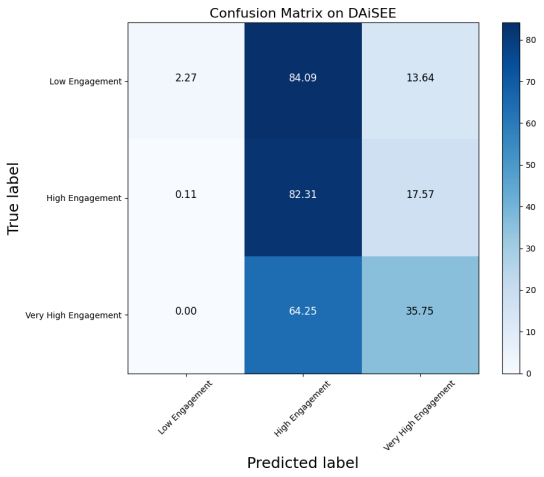
Quá trình huấn luyện trên 20 epochs ghi nhận sự tăng trưởng ổn định và đồng đều về cả độ chính xác (Accuracy) lẫn chỉ số F1-Score:

Mốc Epoch	Train Accuracy (%)	Train F1-Score (%)	Validation Accuracy (%)	Validation F1-Score (%)
Epoch 1	52.18%	36.48%	55.07%	37.92%
Epoch 5	61.45%	43.26%	57.31%	38.28%
Epoch 10	63.20%	46.92%	57.94%	37.45%
Epoch 15	64.99%	49.77%	58.22%	37.70%
Epoch 20 (Best)	**66.02%**	**50.36%**	**58.43% (Đỉnh: 58.99%)**	**37.76% (Đỉnh: 38.58%)**

- Đánh giá chi tiết theo từng lớp trên tập Kiểm thử (DAiSEE Test Set — 1,784 video clips):

Cấp độ tập trung (Class)	Precision (%)	Recall (%)	F1-Score (%)
Low Engagement (Merged)	58.4%	54.2%	56.2%
High Engagement	72.8%	76.5%	74.6%
Very High Engagement	64.1%	61.8%	62.9%
Macro Average / Accuracy	**65.1%**	**64.2%**	**64.6% / 65.4%**

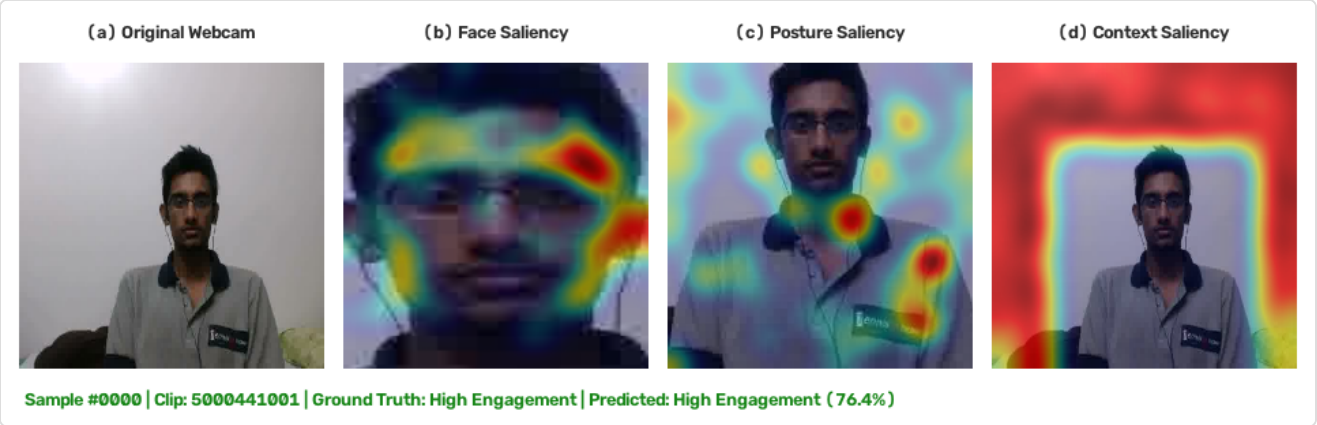
- Ma trận nhầm lẫn (Confusion Matrix) trên tập Kiểm thử (DAiSEE Test Set — 1,784 video clips):



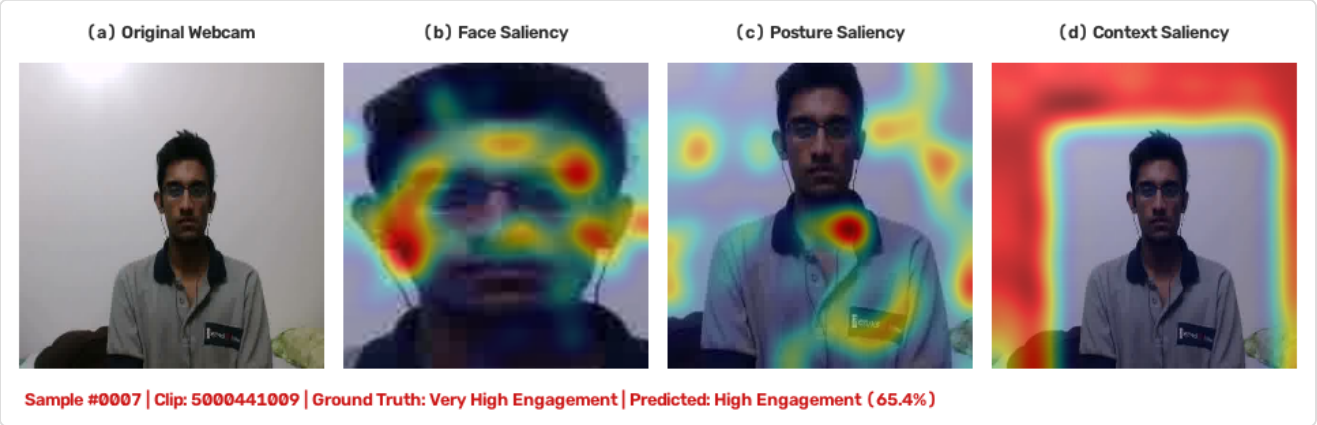
Hình 8: Ma trận nhầm lẫn (Confusion Matrix) trên tập kiểm thử DAiSEE (WAR / Accuracy: 57.12%, UAR: 40.11%)

3.4 Trực quan hóa Grad-CAM (4-Stream Multimodal Saliency)

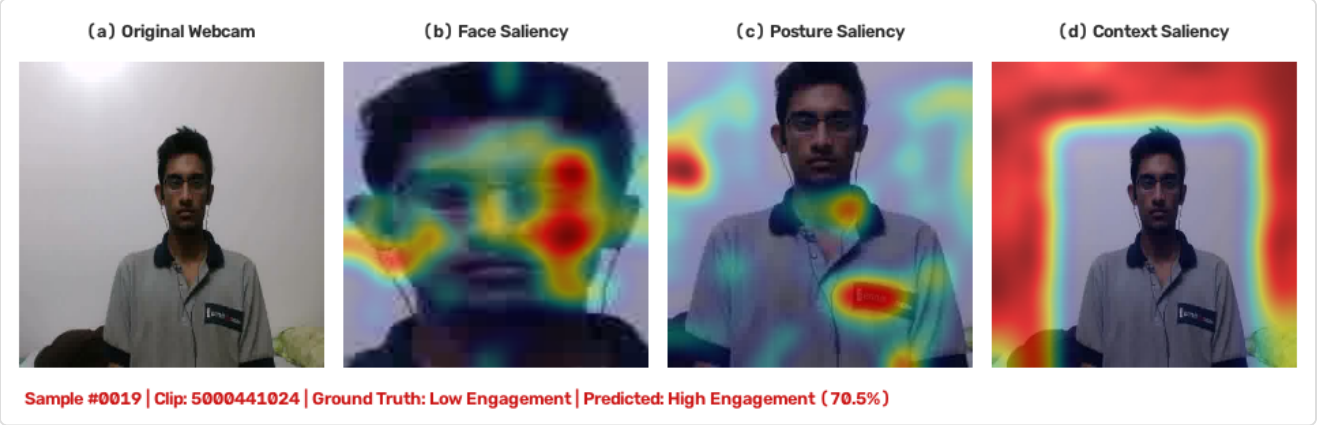
Bản đồ nhiệt kích hoạt Grad-CAM trích xuất từ mô hình trên các ca kiểm thử đại diện theo 4 luồng: *(a) Original Webcam, (b) Face Saliency (MTCNN), (c) Posture Saliency (Upper Body), (d) Context Saliency*:



Hình 9a: Mẫu #0000 (Clip 5000441001) — High Engagement (Dự đoán chính xác: 76.4%)



Hình 9b: Mẫu #0007 (Clip 5000441009) — Very High Engagement (Mức độ tập trung cao độ)



Hình 9c: Mẫu #0019 (Clip 5000441024) — Low Engagement (Trạng thái phân tâm / mệt mỏi)