

BÁO CÁO PHÂN TÍCH KỸ THUẬT: KHUNG HÌNH CAREFL

Context-Aware Recognition of Emotions with Federated Learning (Lopez Quel et al., 2026)

TÓM TẮT DÀNH CHO CHUYÊN GIA NGHIÊN CỨU

Báo cáo này phân tích chuyên sâu về mặt kỹ thuật đối với **CAREFL** — một khung hình nhận dạng cảm xúc trực quan đa nhân kết hợp giữa khả năng suy luận ngữ cảnh của VLM lớn đóng băng (LLaVA 1.5) và tính hiệu quả, bảo mật của VLM nhỏ (SMOLVLM2) phía client. Bằng cách áp dụng **QLoRA 4-bit** trong môi trường **Học liên kết (Federated Learning)** với thuật toán **FedDyn**, CAREFL đạt hiệu năng SOTA (mAP 96.49%, F1-score 55.40%) trong giới hạn bộ nhớ GPU nghiêm ngặt (**< 6 GB**).

1. Tóm tắt ý tưởng cốt lõi (Core Intuition)

Vấn đề chính cần giải quyết:

Nhận dạng cảm xúc con người qua ảnh thực tế đòi hỏi sự thấu hiểu sâu sắc về ngữ cảnh môi trường và tương tác xã hội. Mặc dù các Mô hình Thị giác - Ngôn ngữ lớn (Vision-Language Models - VLMs) như GPT-4o hay LLaVA có khả năng suy luận ngữ cảnh vượt trội, việc triển khai chúng lại gặp rào cản lớn do chi phí tính toán cao, tiêu tốn bộ nhớ GPU khổng lồ và yêu cầu thu thập dữ liệu tập trung (gây nguy cơ mất an toàn quyền riêng tư). Ngược lại, các mô hình mỏng nhẹ trên thiết bị biên tuy nhanh nhưng thiếu khả năng hiểu biết ngữ cảnh phức tạp.

Đóng góp lớn nhất (Main Contribution):

Nhóm tác giả đề xuất **CAREFL** (Context-Aware Recognition of Emotions with Federated Learning), một khung hình tổng quát giúp giải quyết mâu thuẫn giữa hiệu năng ngữ cảnh và chi phí tính toán thông qua cơ chế **phân tách vai trò**:

- Trích xuất Tri thức Ngữ cảnh Offline/Server-side:** Sử dụng VLM lớn đóng băng (frozen LLaVA 1.5) kết hợp YOLOv8 để chuyển đổi thông tin ngữ cảnh môi trường phức tạp thành mô tả văn bản giàu ngữ nghĩa (semantic priors).
- Tinh chỉnh mỏng nhẹ Online/Client-side:** Tinh chỉnh mô hình VLM nhỏ (SMOLVLM2) bằng kỹ thuật **QLoRA 4-bit** trong mạng lưới **Học liên kết (Federated Learning)** với thuật toán **FedDyn**.
- Hiệu năng SOTA & Tiết kiệm tài nguyên:** Đạt mAP 96.49% và F1-score 55.40% trên tập EMOTIC (vượt qua các baseline tập trung như LLaVA và GPT-4o) đồng thời giảm tiêu thụ bộ nhớ GPU gần một nửa (từ 10.98 GB xuống **5.96 GB**).

2. Các công nghệ / Phương pháp nổi bật (Key Technologies)

1. Tạo ngữ cảnh ngữ nghĩa (Context Generation via YOLOv8 + Frozen LLaVA 1.5)

Mô tả: YOLOv8 tự động phát hiện vị trí đối tượng người trong ảnh (bounding box). Vùng ảnh này cùng prompt hệ thống được đưa vào LLaVA 1.5 (frozen) để tạo đoạn mô tả văn bản chi tiết (C_i) về hành động, môi trường và tương tác xã hội xung quanh.

Lý do chọn: VLM lớn có khả năng suy luận ngữ cảnh mạnh mẽ nhưng quá đắt đỏ để fine-tune; việc đóng

bằng LLaVA giúp trích xuất thông tin ngữ cảnh mức cao thành dạng văn bản trung gian có thể chuyển giao mà không tốn chi phí fine-tuning.

2. Mô hình VLM mỏng nhẹ phía Client (Compact VLM - SMOLVLM2)

Mô tả: Sử dụng SMOLVLM2 làm mô hình cơ sở ở client để tiếp nhận cả tín hiệu thị giác (X_{img}) và văn bản ngữ cảnh (C_i), dự đoán chuỗi nhãn cảm xúc theo phương thức tự hồi quy.

Lý do chọn: Kích thước mỏng nhẹ, tối ưu cho việc huấn luyện và suy luận trực tiếp trên các thiết bị biên với tài nguyên phần cứng hạn chế.

3. Thích ứng Thứ hạng Thấp đã Lượng hóa (Quantized Low-Rank Adaptation - QLoRA 4-bit)

Mô tả: Đóng băng toàn bộ trọng số gốc của SMOLVLM2 dưới dạng lượng hóa 4-bit (NF4) và chỉ tinh chỉnh các ma trận adapter LoRA thứ hạng thấp ($r = 4$).

Lý do chọn: Giảm mức tiêu thụ bộ nhớ GPU gần một nửa (từ 10.98 GB xuống 5.96 GB), giảm số lượng tham số huấn luyện xuống 5.24 M và đạt tốc độ suy luận nhanh (0.72 s/ảnh) mà không làm sụt giảm độ chính xác.

4. Học liên kết với Điều chỉnh Động FedDyn (Federated Learning with FedDyn)

Mô tả: Các client chỉ cập nhật trọng số adapter cục bộ và gửi phiên bản adapter đã lượng hóa lên Server trung tâm để tổng hợp bằng thuật toán FedDyn.

Lý do chọn: Đảm bảo tính riêng tư tuyệt đối (không truyền ảnh/text gốc) và giảm tối đa băng thông. Thuật toán FedDyn giải quyết triệt để hiện tượng trôi client (client drift) khi phân bố dữ liệu bị lệch nghiêm trọng (non-IID).

3. Các Công thức Toán học trọng tâm (Key Formulas)

CÔNG THỨC 1: HÀM MẤT MẤT TỐI ƯU HÓA CỤC BỘ (AUTOREGRESSIVE CROSS-ENTROPY LOSS)

$$L_{CE}(\theta) = - \sum_{t=1..T} \log P(y_t | y_{<t}, X_{img}, C_i; \theta)$$

Giải thích chi tiết ý nghĩa vật lý & toán học từng biến số:

- $L_{CE}(\theta)$:** Hàm mất mát Cross-Entropy đo lường độ chênh lệch giữa phân bố xác suất dự đoán của mô hình và chuỗi nhãn cảm xúc thực tế.
- θ :** Tập hợp các tham số huấn luyện được của adapter QLoRA tại client (trọng số nền của SMOLVLM2 đã bị đóng băng 4-bit).
- X_{img} :** Tín hiệu hình ảnh đầu vào chứa đối tượng người cần phân tích cảm xúc.
- C_i :** Chuỗi văn bản mô tả ngữ cảnh (Contextual Narrative) do LLaVA 1.5 tạo ra từ ảnh ($C_i = f_{LLaVA}(X_{img}, \text{prompt})$).
- $y = [y_1, y_2, \dots, y_T]$:** Chuỗi nhãn cảm xúc mục tiêu đã được chuỗi hóa dạng văn bản (ví dụ: `[Happy, Surprised]`).
- y_t :** Token thứ t trong chuỗi nhãn cảm xúc tại bước sinh tự hồi quy t .
- $y_{<t}$:** Tập hợp tất cả các token nhãn đã được mô hình sinh ra ở các bước trước ($y_1, \dots, y_{t-1}$).
- $P(y_t | y_{<t}, X_{img}, C_i; \theta)$:** Xác suất điều kiện mô hình dự đoán đúng token nhãn y_t dựa trên ảnh X_{img} , văn bản ngữ cảnh C_i và lịch sử token $y_{<t}$.

CÔNG THỨC 2: MỤC TIÊU TỐI ƯU HÓA ĐIỀU CHỈNH ĐỘNG FEDDYN TẠI CLIENT

$$L_k^{\text{FedDyn}}(\theta) = L_{\text{CE}}(\theta) - \langle h_k^t, \theta \rangle + (\alpha_{\text{FD}} / 2) || \theta - \theta^t ||^2$$

Giải thích chi tiết ý nghĩa vật lý & toán học từng biến số:

- $L_k^{\text{FedDyn}}(\theta)$:** Hàm mục tiêu tối ưu tổng thể của client k tại vòng truyền thông t trong môi trường Federated Learning.
- $L_{\text{CE}}(\theta)$:** Hàm mất mát Cross-Entropy tính trên dữ liệu riêng tư cục bộ của client k.
- θ^t :** Trọng số adapter toàn cục (Global Model Adapter Parameters) do Server trung tâm phát xuống ở đầu vòng t.
- h_k^t :** Vector ký nhớ gradient (gradient memory vector) tích lũy độ lệch giữa gradient cục bộ của client k và gradient toàn cục qua các vòng.
- $\langle h_k^t, \theta \rangle$:** Tích vô hướng đại diện cho thuật ngữ chỉnh sửa tuyến tính (linear correction term), giúp định hướng bước cập nhật gradient của client về phía điểm cân bằng toàn cục.
- α_{FD} :** Siêu tham số phạt điều chỉnh (regularization factor) kiểm soát độ mạnh của ràng buộc (trong bài thử nghiệm $\alpha_{\text{FD}} \in \{0.01, 1.0, 5.0\}$).
- $|| \theta - \theta^t ||^2$:** Chuẩn L2 bình phương đo khoảng cách giữa trọng số adapter cục bộ θ và trọng số toàn cục θ^t , đóng vai trò lực kéo giữ client không cập nhật trọng số đi quá xa khỏi mô hình chung.

4. Luồng hoạt động chi tiết (Pipeline / Architecture Workflow)

Bảng so sánh hiệu năng và chỉ số kỹ thuật của CAREFL:

Tập dữ liệu	Cấu hình / Mô hình	mAP (%)	F1-Score (%)	GPU Memory	Thời gian/ảnh
EMOTIC	CAREFL (10 Clients, 100%)	96.49%	55.40%	5.96 GB	0.72 s
EMOTIC	LLaVA 1.5 (Centralized)	88.12%	42.10%	10.98 GB	2.10 s
EMOTIC	GPT-4o (Zero-shot)	79.35%	35.80%	N/A (API)	1.85 s
CAER-S	CAREFL (Non-IID, $\alpha=0.1$)	82.33%*	78.10%	5.96 GB	0.72 s

* Ghi chú: Kết quả trên CAER-S đo bằng độ chính xác Accuracy. Dữ liệu trích từ báo cáo CAREFL (2026).

Quy trình vận hành theo trình tự thời gian (10 bước chi tiết):

GAİI ĐOẠN I: TẠO NGỮ CẢNH VỚI VLM LỚN (OFFLINE / SERVER-SIDE)

- Bước 1: Tiếp nhận Dữ liệu Đầu vào (Input):** Hệ thống nhận ảnh thực tế gốc X_{img} chứa hình ảnh người và quang cảnh xung quanh.
- Bước 2: Định vị Đối tượng (Object Detection):** Mô hình YOLOv8 quét ảnh và tự động xác định vị trí người, khoanh vùng bằng khung bounding box.
- Bước 3: Trích xuất Suy luận Ngữ cảnh (Context Narrative):** LLaVA 1.5 (frozen) tiếp nhận vùng ảnh và sinh văn bản mô tả C_i về môi trường, hoạt động và tương tác xung quanh.
- Bước 4: Đóng gói Bộ ba Dữ liệu (Triplet Structuring):** Ghép nối thành bộ ba dữ liệu (X_{img}, C_i, Y) với Y là chuỗi nhãn cảm xúc thực tế (Ground Truth).

GIẢI ĐOẠN II: HUẤN LUYỆN THÍCH ỨNG LIÊN KẾT VỚI QLoRA (ONLINE / FEDERATED FINE-TUNING)

- **Bước 5: Khởi tạo Toàn cục & Phân phối (Distribution):** Server trung tâm khởi tạo bộ tham số adapter toàn cục θ^t và gửi xuống cho các client.
- **Bước 6: Thiết lập Mô hình tại Client (Local Setup):** Client nạp mô hình SMOLVLM2 dạng lượng hóa 4-bit và cập nhật trọng số adapter θ^t .
- **Bước 7: Huấn luyện Tự hồi quy Cục bộ (Local Training):** Client kết hợp ảnh X_{img} và văn bản C_i để tính hàm loss $L_k^{FedDyn}(\theta)$, lan truyền ngược cập nhật QLoRA adapter.
- **Bước 8: Truyền gửi Thông số Bảo mật (Private Updates):** Client chỉ gửi duy nhất adapter θ_k đã lượng hóa về Server (dữ liệu ảnh X_{img} và text C_i được giữ nguyên tại client).
- **Bước 9: Tổng hợp Trọng số tại Server (Server Aggregation):** Server dùng thuật toán FedDyn tổng hợp trọng số adapter từ các client để tạo bộ trọng số toàn cục mới θ^{t+1} .
- **Bước 10: Xuất Kết quả / Suy luận (Output Generation):** Mô hình dự đoán và xuất chuỗi danh mục cảm xúc đa nhãn hoàn chỉnh (ví dụ: `['Engagement', 'Excitement']`).

KẾT LUẬN & ĐÁNH GIÁ TỔNG QUAN

Khung hình **CAREFL** chứng minh rằng việc kết hợp thông minh giữa VLM lớn đóng băng làm 'bộ tạo ngữ cảnh' và VLM nhỏ tinh chỉnh bằng QLoRA 4-bit trong Học liên kết là một hướng đi đột phá. Phương pháp này vừa giúp tối ưu hóa tài nguyên phần cứng (dưới 6 GB GPU), vừa giải quyết triệt để bài toán bảo mật dữ liệu cá nhân mà vẫn đạt hiệu năng vượt trội so với các mô hình tập trung lớn.