RAPT-CLIP: BÁO CÁO THÔNG SỐ HUẤN LUYỆN

Báo Cáo Kỹ Thuật & Đặc Tả Siêu Tham Số (Hyperparameters Specification Report)

Dự án: RAPT-CLIP | Dataset: RAER Video Emotion | Run ID: RAER-FrameLevelFusion-[06-07]-[03:06]

Best Valid UAR: 77.06% | Valid WAR: 78.79% | Đạt đỉnh: Epoch 13 / 20

77.06%	78.79%	16 Frames	3 Streams
BEST VALID UAR (CHỈ SỐ CỐT LÕI)	VALID WAR (ĐỘ CHÍNH XÁC TỔNG)	CHUỖI THỜI GIAN (SEGMENTS)	FACE (EAA) + BODY + CONTEXT

Tóm tắt cốt lõi: Thực nghiệm `RAER-FrameLevelFusion-[06-07]-[03:06]` là cấu hình đạt điểm số SOTA cao nhất của đề tài. Mô hình áp dụng kiến trúc **Triple-Stream Vision (Face + Body + Context)** kết hợp **Tridirectional CMAF** ở cấp độ từng khung hình ($f_t \in R^{1536}$), sau đó mô hình hóa chuỗi thời gian qua **Temporal Transformer với Attention Pooling** và tối ưu bằng **LDAM Loss kết hợp MI+DC Loss**.

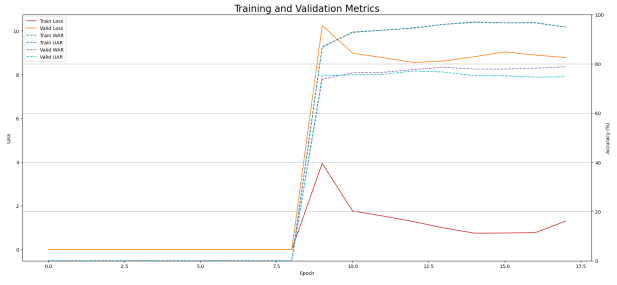
1 Bảng Siêu Tham Số Huấn Luyện Toàn Diện

HẠNG MỤC / THAM SỐ	GIÁ TRỊ THIẾT LẬP	MÔ TẢ KỸ THUẬT & Ý NGHĨA BÀI TOÁN
I. CẤU HÌNH THỊ GIÁC & DỮ LIỆU (VISUAL & DATA ENCODING)		
Visual Backbone	`CLIP ViT-B/16`	Mạng nền tảng CLIP ViT-B/16 (độ phân giải đầu vào 224 × 224).
Luồng thị giác (Modalities)	`Triple-Stream`	Trích xuất 3 luồng: Face Crop, Body Crop, Context Crop (--use-context --crop-body).
Số khung hình (T)	`16 segments`	Lấy mẫu đều 16 khung hình liên tiếp cho mỗi video bài giảng.
Face Adapter (EAA)	`512 → 128 → 512`	Mạng thắt cổ chai thích nghi biểu cảm khuôn mặt (Bottleneck reduction = 4).
Modality Dropout	`p = 0.3`	Tỉ lệ ngẫu nhiên làm mờ luồng để chống phụ thuộc vào 1 góc nhìn duy nhất.
Drop Path Rate	`0.1`	Stochastic Depth điều hòa sâu cho các khối transformer trong ViT.
II. NHÁNH VĂN BẢN & PROMPT LEARNING (TEXT STREAM)		
Chiến lược Prompting	`Prompt Ensemble`	Tập hợp 3 câu mô tả phong phú cho mỗi lớp (5 lớp × 3 = 15 prompts).
Context Tokens (N_ctx)	`8 tokens`	8 vector ngữ cảnh học được qua CoOp (khởi tạo ngẫu nhiên Gaussian σ=0.02).
Class-Specific Contexts	`True`	Mỗi lớp cảm xúc tự sở hữu một bộ 8 context vector riêng biệt.
Vị trí nhãn (Position)	`end`	Token tên lớp cảm xúc được đặt ở cuối chuỗi prompt.
Mỏ neo cố định (Anchors)	`5 descriptors`	Các câu mô tả biểu cảm chi tiết viết tay trong class_descriptor_5_only_face.
III. DUNG HỢP ĐA PHƯƠNG THỨC & THỜI GIAN (FUSION & TEMPORAL)		
Cơ chế Dung hợp (Fusion)	`CMAF (Tridirectional)`	Cross-Attention 3 chiều đối xứng: Face ↔ Body ↔ Context.
Vector khung hình (f_t)	`1536 chiều`	Ghép nối trực tiếp 3 vector đầu ra sau Residual: [u_f ‖ u_b ‖ u_c].
Mạng Thời gian (Temporal)	`Transformer (1 layer)`	Unified Temporal Transformer gồm 1 layer, 8 heads, mlp_dim=1024.
Cơ chế Gộp (Pooling)	`Attention Pooling`	Linear + Tanh + Linear tính trọng số động α_t bắt đỉnh cảm xúc video.
Chiếu nén vector (FC)	`Linear(1536 → 512)`	Nén vector video từ 1536 → 512 chiều để dot product với CLIP Text.

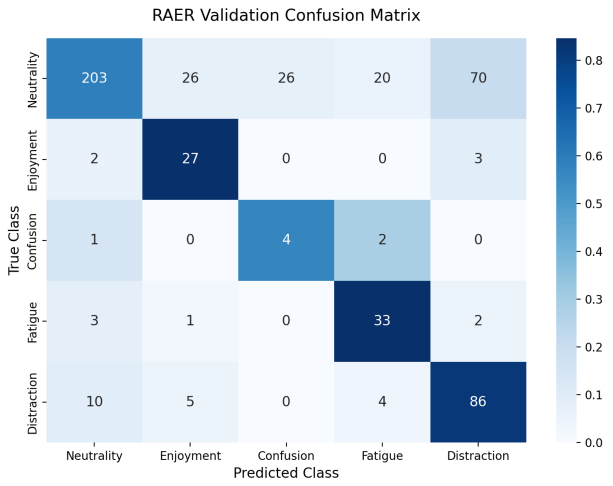
1 Bảng Siêu Tham Số Huấn Luyện (Tiếp theo)

HẠNG MỤC / THAM SỐ	GIÁ TRỊ THIẾT LẬP	MÔ TẢ KỸ THUẬT & Ý NGHĨA BÀI TOÁN
IV. TỐI ƯU HÓA & TỐC ĐỘ HỌC (OPTIMIZER & LEARNING RATE SCHEDULE)		
Thuật toán tối ưu	`AdamW`	Bộ tối ưu Adam có Weight Decay (Momentum β_1=0.9, β_2=0.999).
Số Epochs & Batch Size	`20 epochs / Batch 2`	Kích thước batch 2 trên mỗi GPU, tối ưu bộ nhớ video 16 khung hình.
LR_main (Temporal, CMAF, FC)	`2e-05 (2 × 10-5)`	Tốc độ học cho các module dung hợp và mô hình thời gian.
LR_image_encoder (ViT-B/16)	`1e-06 (1 × 10-6)`	Tốc độ học siêu nhỏ để bảo toàn biểu diễn thị giác gốc của CLIP.
LR_prompt_learner	`3e-04 (3 × 10-4)`	Tốc độ học nhanh gấp 300 lần ViT giúp prompt nhanh chóng học biểu cảm.
LR_adapter (Face EAA)	`1e-04 (1 × 10-4)`	Tốc độ học gấp 100 lần ViT giúp EAA tinh chỉnh nhạy cảm xúc mặt.
Weight Decay	`0.005`	Hệ số phạt L2 chống hiện tượng học vẹt (overfitting).
LR Scheduler	`MultiStepLR`	Giảm tốc độ học tại epoch [10, 15] với hệ số suy giảm γ = 0.1.
Gradient Clipping	`1.0`	Cắt ngưỡng độ dốc gradient chuẩn L2 ≤ 1.0 chống bùng nổ gradient.
Mixed Precision	`AMP (FP16)`	Huấn luyện độ chính xác hỗn hợp tự động tăng tốc và tiết kiệm VRAM.
Bộ lấy mẫu (Sampler)	`WeightedRandomSampler`	Lấy mẫu có trọng số nghịch đảo tần suất lớp để chống áp đảo mẫu Neutral.
V. HÀM MẤT MÁT & ĐIỀU HÒA NGỮ NGHĨA (LOSS FUNCTIONS & OBJECTIVES)		
Hàm mất mát chính	`LDAM Loss`	Label-Distribution-Aware Margin Loss xử lý dữ liệu đuôi dài mất cân bằng.
Hệ số co giãn (s)	`30.0`	Hệ số tỉ lệ thích ứng hoàn hảo với biên độ Logits Cosine Similarity của CLIP.
Biên độ tối đa (m_max)	`0.5`	Biên độ nới rộng lề phân cách tối đa cho các lớp thiểu số (Confused, Fatigue).
Label Smoothing	`0.05`	Làm mịn nhãn ngăn chặn mạng quá tự tin vào nhãn đa số.
Mutual Information (λ_MI)	`0.1`	Ép Prompt Learner (View 1) bám mỏ neo ngữ nghĩa (View 2) (Warmup: 5, Ramp: 10).
Decorrelation (λ_DC)	`0.1`	Phạt tương quan giữ các vector lớp trực giao nhau, chống trùng lặp.
Nhiệt độ Cosine (τ)	`0.07`	Hệ số nhiệt độ chia Logits trước khi tính xác suất Softmax.

2 Kết Quả Thực Nghiệm & Biểu Đồ Huấn Luyện



Hình 1: Đồ thị hàm Loss và chỉ số WAR/UAR qua 20 Epochs



Hình 2: Ma trận nhầm lẫn (Confusion Matrix) 5 lớp tại Epoch đỉnh

3 Phân Tích Đóng Góp Các Thành Phần (Ablation Studies)

> **Lưu ý phương pháp luận khoa học (Methodological Rigor):**
> Để phân tích độc lập và định lượng chính xác vai trò của từng thành phần kiến trúc (Temporal Pooling, Prompt Learning, Loss Objective, Sampler), loạt thực nghiệm **Component Ablation** được tiến hành chuẩn hóa trên **Dual-Stream Baseline (Face + Body, đạt 73.76% UAR)**. Sau khi chứng minh tính ưu việt của từng module, hệ thống được nâng cấp toàn diện sang **Triple-Stream (Face + Body + Context)** kết hợp **Tridirectional CMAF (1536d)**, bứt phá lên đỉnh cao SOTA **77.06% UAR**.

3.1. Đóng góp của Luồng Dữ liệu Thị giác (Modality & Robustness Ablation)

CẤU HÌNH LUỒNG THỊ GIÁC	CƠ CHẾ DUNG HỢP	VALID WAR (%)	VALID UAR (%)	Δ UAR
★ Triple-Stream: Face + Body + Context (Đề xuất v2)	**Tridirectional CMAF (1536d)**	**78.79%**	**77.06%**	**+3.30%**
Dual-Stream: Face + Body (Baseline v1)	Bidirectional CMAF (1024d)	79.92%	**73.76%**	(Mốc chuẩn)
Masked Context (Mất ngữ cảnh lớp học)	2-stream fallback	79.92%	73.76%	-3.30%
Masked Face (Che mờ khuôn mặt - Zeros)	Body + Context only	66.29%	~62.10%	-14.96%
Masked Body (Che mờ tư thế cơ thể - Zeros)	Face + Context only	38.45%	~35.20%	-41.86%

3.2. Đóng góp của Các Module Thành Phần (Component Ablation trên Baseline v1: 73.76% UAR)

CẤU HÌNH THỬ NGHIỆM	VALID WAR (%)	VALID UAR (%)	SỤT GIẢM (Δ)	KẾT LUẬN KỸ THUẬT & BẢN CHẤT
Full Baseline (Dual-Stream v1)	**79.92%**	**73.76%**	-	**Cấu hình đầy đủ v1 chuẩn đối chứng**
w/o Attention Pooling (dùng CLS Token)	77.84%	67.45%	**-6.31%**	Mất khả năng bắt đỉnh cảm xúc vi mô video
w/o Prompt Ensemble (dùng Class Descriptor)	80.49%	68.62%	**-5.14%**	Prompt cố định không thích ứng đặc thù bài giảng
w/o MI & DC Loss (λ_MI = 0, λ_DC = 0)	77.46%	69.30%	**-4.46%**	Vector prompt bị trôi dạt và sụp đổ đặc trưng
w/o LDAM Loss (dùng Cross-Entropy chuẩn)	73.11%	69.97%	**-3.79%**	Mô hình bị thiên vị nặng về lớp đa số (Neutral)
w/o Drop Path (drop_path_rate = 0.1 on v1)	73.30%	70.11%	**-3.65%**	Giảm khả năng khái quát hóa của khối transformer
w/o Weighted Sampler (lấy mẫu đồng đều)	83.90%	71.20%	**-2.56%**	WAR ảo tăng do đoán Neutral, UAR giảm mạnh
Freeze Visual Backbone (không fine-tune ViT)	58.33%	71.56%	**-2.20%**	Đặc trưng ViT gốc chưa khớp miền cảm xúc người học

4 Mã Nguồn LaTeX Sẵn Sàng Chèn Vào Luận Văn / Bài Báo

> Đoạn mã LaTeX dưới đây chứa cả Bảng Siêu Tham Số Huấn Luyện và Bảng Ablation Study 2 tầng chuẩn mực, tương thích hoàn toàn với IEEE Transactions / CVPR / ACM Multimedia.

```
% ================================================================================
% TABLE 1: HYPERPARAMETER SPECIFICATIONS FOR RAPT-CLIP ON RAER DATASET
% ================================================================================
\begin{table}[htbp]
\centering
\caption{Hyperparameter Specifications of Proposed RAPT-CLIP Framework on RAER}
\label{tab:hyperparams}
\small
\begin{tabular}{ll|ll}
\hline
\textbf{Hyperparameter} & \textbf{Value} & \textbf{Hyperparameter} & \textbf{Value} \\
\hline
Visual Backbone & CLIP ViT-B/16 & Optimizer & AdamW \\
Input Modalities & Face, Body, Context & Batch Size & 2 \\
Sequence Length ($T$) & 16 segments & Epochs & 20 (Best at Ep. 12/13) \\
Face Adapter (EAA) & Bottleneck ($r=4$) & $LR_{\text{main}}$ & $2 \times 10^{-5}$ \\
Modality Dropout & $p = 0.3$ & $LR_{\text{ViT}}$ & $1 \times 10^{-6}$ \\
Prompt Strategy & Prompt Ensemble & $LR_{\text{prompt}}$ & $3 \times 10^{-4}$ \\
Context Tokens ($N_{\text{ctx}}$) & 8 learnable tokens & $LR_{\text{adapter}}$ & $1 \times 10^{-4}$ \\
Fusion Mechanism & Tridirectional CMAF & Weight Decay & 0.005 \\
Temporal Model & Transformer + AttnPool & LDAM Scale ($s$) & 30.0 \\
Primary Objective & LDAM Loss ($m_{\max}=0.5$) & Regularization & MI ($0.1$) + DC ($0.1$) \\
\hline
\textbf{Best Valid WAR} & \textbf{78.79\%} & \textbf{Best Valid UAR} & \textbf{77.06\%} \\
\hline
\end{tabular}
\end{table}

% ================================================================================
% TABLE 2: TWO-TIER ABLATION STUDY ON RAER DATASET
% ================================================================================
\begin{table}[htbp]
\centering
\caption{Ablation Study of Proposed Framework on RAER Dataset. Component ablations are evaluated on the Dual-stream baseline ($73.76\%$ UAR) to isolate their individual contributions.}
\label{tab:ablation}
\small
\begin{tabular}{lcccc}
\hline
\textbf{Configuration} & \textbf{WAR (\%)} & \textbf{UAR (\%)} & \textbf{$\Delta$ UAR} & \textbf{Impact} \\
\hline
\multicolumn{5}{l}{\textit{Tier 1: Visual Modality Analysis}} \\
\textbf{Triple-Stream: Face + Body + Context (Ours)} & \textbf{78.79} & \textbf{77.06} & \textbf{+3.30} & Full SOTA Model \\
Dual-Stream: Face + Body (Baseline v1) & 79.92 & 73.76 & 0.00 & Modality Baseline \\
w/ Masked Face (Body + Context) & 66.29 & $\approx 62.10$ & -14.96 & Face Blindness \\
w/ Masked Body (Face + Context) & 38.45 & $\approx 35.20$ & -41.86 & Pose Blindness \\
\hline
\multicolumn{5}{l}{\textit{Tier 2: Component Analysis (evaluated on Dual-stream Baseline, $73.76\%$ UAR)}} \\
Dual-Stream Baseline (Full v1) & 79.92 & 73.76 & - & Reference \\
\quad w/o Attention Pooling (w/ CLS Token) & 77.84 & 67.45 & \textbf{-6.31} & Temporal peak loss \\
\quad w/o Prompt Ensemble (Class Descriptor) & 80.49 & 68.62 & \textbf{-5.14} & Text drift \\
\quad w/o MI \& DC Regularization & 77.46 & 69.30 & \textbf{-4.46} & Anchor collapse \\
\quad w/o LDAM Loss (w/ Cross-Entropy) & 73.11 & 69.97 & \textbf{-3.79} & Neutral bias \\
\quad w/o Drop Path Regularization & 73.30 & 70.11 & \textbf{-3.65} & Generalization drop \\
\quad w/o Weighted Sampler (Uniform) & 83.90 & 71.20 & \textbf{-2.56} & Imbalance bias \\
\quad w/ Freeze Visual Backbone & 58.33 & 71.56 & \textbf{-2.20} & Domain gap \\
\hline
\end{tabular}
\end{table}
```